


Hybrid

Quantum-Classical Neural Network

Pneumonia Detection in Chest X-Rays

Michal Forgó

University of West Bohemia & SŠINFIS



Konec Moorova zákona a motivace pro kvantové počítání

- **Moorův zákon** (Gordon Moore, 1965): Počet tranzistorů na čipu se zdvojnásobuje přibližně každé 2 roky.
- Tento trend platil po několik desetiletí, ale v posledních letech **zpomaluje** v důsledku fyzikálních limitů křemíkové technologie (kvantové tunelování, tepelný disipace).

Důsledek

Další zvyšování výkonu klasických procesorů je stále obtížnější a nákladnější – hledají se **nová výpočetní paradigmata**.

- **Kvantové počítání** nabízí alternativu: s využitím superpozice a entanglementu dokáže řešit určité třídy problémů exponenciálně rychleji než klasické počítače.
- Tento projekt zkoumá, zda lze kvantové klasifikátory (VQC) s minimálním počtem parametrů využít v **hybridních kvantově-klasických modelech** pro medicínskou diagnostiku – i v době NISQ (*Noisy Intermediate-Scale Quantum*).

Overview

Clinical Motivation Context

- **The Problem:** Pneumonia causes ~ 2.5 million deaths annually[cite: 8].
- **Current State:** Deep Learning (ResNet, DenseNet) achieves high accuracy ($> 85\%$) but requires massive parameter counts ($164.8k+$ per layer)[cite: 9].
- **The Opportunity:** NISQ quantum devices offer parameter-efficient learning via VQA[cite: 10].

Research Hypothesis

A quantum decision layer (VQC with ~ 100 parameters) can approach classical discrimination while reducing memory footprint, enabling Edge/IoT deployment[cite: 12].

Hybrid Architecture Design

Design Rationale: Separate feature learning (classical) from decision making (quantum).

Pipeline Flow:

- 1. **Input:** Chest X-Ray (224×224).
- 2. **Feature Extraction:** ConvNeXt-Tiny (frozen) $\rightarrow$ 768-D vector.
- 3. **Compression:** PCA/Autoencoder ($768 \rightarrow 64$).
- 4. **Classification:** VQC (6 qubits, 54 params).

Stage	Operation	Params
Features	ConvNeXt-Tiny	0 (frozen)
Reduction	PCA/Autoencoder	0 (fixed)
Decision	VQC (6-qubit)	54

tableParameter counts [cite: 22]

Quantum Circuit Theory

Amplitude Encoding: Mapping vector $x \in \mathbb{R}^{64}$ to quantum state:

$$|\psi(x)\rangle = \sum_{i=0}^{63} x_i |i\rangle \in \mathcal{H}_{2^6}$$

VQC Prediction: Defined by the expectation value:

$$f(x, \theta) = \langle \psi(x) | U^\dagger(\theta) Z_0 U(\theta) | \psi(x) \rangle \in [-1, 1]$$

Optimized via weighted mean squared error on simulator (PennyLane)[cite: 43].

Performance vs. Efficiency

The VQC decision head achieves competitive results with massive parameter reduction.

Parameter Efficiency:

- Classical MLP: 2,113 params.
- Quantum VQC: **54 params.**
- **Reduction: 39×**[cite: 58].

Diagnostic Accuracy (AUC):

- Classical MLP: 0.940 AUC.
- Hybrid VQC: **0.974 AUC**[cite: 66].

Note: Specificity drops due to dataset shift and barren plateaus[cite: 69].

Thank You for Your Attention

Questions?

Contact: mforgo@example.com

References