

Anotace

Tato práce zkoumá využití kvantového strojového učení (QML) pro detekci zápalu plic z rentgenových snímků hrudníku. Cílem bylo navrhnout, implementovat a ověřit hybridní architekturu na simulátoru kvantového počítače. Jako extraktor příznaků slouží konvoluční síť ConvNeXt-Tiny. Získané příznaky jsou redukovány pomocí autoenkodéru a klasifikovány kvantovým modelem: Variačním kvantovým klasifikátorem (VQC) s *data re-uploading* ansatzem.

Model byl evaluován na simulátoru. Výsledky se statisticky porovnávají s klasickým vícevrstevným perceptronem (MLP). Práce prokazuje, že kvantové modely v éře NISQ dosahují prakticky srovnatelné přesnosti s klasickými sítěmi (rozdíl 1,28 % bodu) při řádově nižším počtu parametrů. Klinická interpretovatelnost je zajištěna vizualizací Grad-CAM.

Klíčová slova: strojové učení; kvantové počítání; detekce pneumonie; NISQ; hybridní model; data re-uploading

Abstract

This thesis investigates quantum machine learning (QML) for detecting pneumonia from chest X-rays. The objective was to design, implement, and validate a hybrid architecture on a quantum simulator. A ConvNeXt-Tiny network extracts features, which are dimensionally reduced via an autoencoder and classified by a quantum model: a Variational Quantum Classifier (VQC) utilizing a *data re-uploading* ansatz.

The model was evaluated on a simulator. Performance is statistically compared against a classical Multi-Layer Perceptron (MLP). The results demonstrate that NISQ-era quantum models achieve practically comparable accuracy to classical networks (1.28 % point difference) with orders of magnitude fewer trainable parameters. Clinical interpretability is ensured via Grad-CAM visualization.

Keywords: machine learning; quantum computing; pneumonia detection; NISQ; hybrid model; data re-uploading

Kapitola 1

Úvod

Rychlý rozvoj umělé inteligence a hlubokého učení v posledním desetiletí zásadním způsobem transformoval řadu oborů, přičemž medicínská diagnostika patří mezi ty nejvíce ovlivněné. Konvoluční neuronové sítě (CNN) dnes dosahují při analýze rentgenových snímků přesnosti srovnatelné s lidskými experty.

Přesto naráží klasické křemíkové čipy na své fyzikální limity, zejména pokud jde o výpočetní náročnost trénování stále komplexnějších modelů. Do popředí zájmu se tak dostává kvantové počítání, které slibuje revoluci ve způsobu zpracování informací. V současné době se oblast kvantových technologií nachází v éře, kterou John Preskill definoval jako NISQ (Noisy Intermediate-Scale Quantum). Jedná se o období, kdy jsou k dispozici kvantové procesory s desítkami až stovkami fyzických qubitů. Tyto procesory sice již nejsou triviální, ale zároveň ještě nejsou dostatečně robustní a chybově korigované (fault-tolerant), aby mohly provádět libovolně dlouhé algoritmy bez vlivu šumu a dekoherence. I v tomto nedokonalém prostředí se již podařilo na reálném hardwaru provést výpočty, které naznačují dosažení tzv. kvantové výhody či dokonce kvantové nadvlády (quantum supremacy). Experimenty společností jako Google či IBM ukázaly, že kvantové čipy dokáží vyřešit specifické matematické úlohy řádově rychleji než nejvýkonnější klasické superpočítače.

Je však nutné podotknout, že tato tvrzení jsou předmětem vědeckých diskusí a kontroverzí, neboť klasické algoritmy jsou neustále optimalizovány a hranice mezi tím, co je a není klasicky simulovatelné, se dynamicky posouvá. Zásadní otázkou, kterou si tato práce klade, je aplikovatelnost těchto principů v oblasti strojového učení (Quantum Machine Learning – QML). Je sporné, zda v éře NISQ, která je charakteristická vysokou chybovostí a nedostatkem logických qubitů, lze očekávat reálné zlepšení oproti vyspělým klasickým neuronovým sítím. Rušení kvantových stavů může v mnoha případech zcela degradovat teoretickou výhodu, kterou kvantový paralelizmus nabízí.

Tato práce se pokouší na tuto otázku odpovědět prostřednictvím návrhu a experimentálního ověření pokročilé hybridní kvantově-klasické architektury. Namísto snahy o čistě kvantové řešení je osvědčená klasická konvoluční síť ConvNeXt-Tiny, sloužící k efektivní extrakci příznaků z medicínských snímků, spojena s moderními kvantovými modely. Práce se neomezuje pouze na základní variační kvantové obvody (VQC), ale pro radikální zvýšení expresivity modelu je aplikována technika tzv. *data re-uploading*.

Zásadním posunem této práce oproti běžným teoretickým studiím je důraz na parametry relevantní pro NISQ éru – omezený počet qubitů a hloubku obvodů. Cílem práce tedy není pouze ukázat, zda kvantové algoritmy absolutně překonají ty klasické v přesnosti, ale prokázat, že i s dramaticky menším počtem parametrů dokáží kvantové modely z dat extrahovat vysoce relevantní diskriminační znaky. Klinická využitelnost a transparentnost navrženého řešení je v

závěru podpořena vizualizací pozornosti sítě pomocí metod interpretovatelné umělé inteligence (Grad-CAM).

Kapitola 2

Teoretická část

2.1 Medicínská východiska

Pneumonie, běžně označovaná jako zápal plic, představuje jedno z nejrozšířenějších a nejzávažnějších respiračních onemocnění celosvětově. Jedná se o akutní zánětlivý proces postihující plicní parenchym, konkrétně plicní sklípky (alveoly) a terminální bronchioly, které se v důsledku zánětu plní tekutinou a hnisem. Tento stav výrazně omezuje schopnost plic absorbovat kyslík, což vede k respirační nedostatečnosti [1]. Podle statistik Světové zdravotnické organizace (WHO) patří pneumonie mezi hlavní příčiny úmrtí dětí do pěti let a představuje významné riziko pro seniory a imunokompromitované pacienty.

2.1.1 Etiologie a klasifikace

Původci onemocnění mohou být různého charakteru, přičemž správná identifikace patogenu je klíčová pro zvolení adekvátní léčby. Nejčastěji se setkáváme s pneumonií:

- **Bakteriální:** Nejběžnějším původcem je *Streptococcus pneumoniae*. Tento typ se často projevuje náhlým nástupem a na rentgenových snímcích mívá charakteristický obraz lobární konsolidace (poškození celého laloku).
- **Virovou:** Způsobenou viry chřipky (Influenza), RSV nebo koronaviry (např. SARS-CoV-2). Virové pneumonie mají tendenci vykazovat difúznější nález a postihovat interstitium (vazivovou tkáň plic) [2].
- **Atypickou a mykotickou:** Způsobenou méně běžnými organismy, jako jsou mykoplazmata nebo houby.

2.1.2 Diagnostika pomocí skiografie hrudníku

Ačkoliv je výpočetní tomografie (CT) považována za citlivější metodu pro detailní zobrazení plicních patologií, základním pilířem diagnostiky zůstává konvenční skiografie hrudníku (rentgen, CXR). Důvody jsou pragmatické: rentgenové vyšetření je rychlé, levné, široce dostupné a vystavuje pacienta výrazně nižší dávce ionizujícího záření než CT [3]. Na rentgenovém snímku se zdravá plicní tkáň, která je naplněná vzduchem, jeví jako tmavá oblast (radiolucenční). Naopak patologické procesy spojené s pneumonií, jako jsou zánětlivé výpotky a buněčná infiltrace, absorbují rentgenové záření více, a proto se na snímku zobrazují jako světlá až bílá zastínění (opacity). Lékař-radiolog při popisu snímku hledá specifické příznaky:

- **Konsolidace:** Oblast plic, kde byl vzduch nahrazen tekutinou, jeví se jako jasná bílá skvrna.
- **Vzdušný bronchogram:** Viditelné průdušky procházející zkonsolidovanou tkání.
- **Infiltráty:** Méně ohraničená zastínění, která mohou být skvrnitá nebo difuzní.

2.1.3 Limitace manuální diagnostiky a role AI

Interpretace rentgenových snímků je vysoce náročný proces, který vyžaduje zkušeného radiologa. I přesto je tento proces zatížen určitou mírou subjektivity. Studie ukazují, že shoda mezi různými radiology (inter-observer variability) není stoprocentní, zejména u hraničních nálezů nebo u snímků s nízkým kontrastem [4]. Mezi hlavní problémy manuální diagnostiky patří:

1. **Vizuální podobnost patologií:** Obraz pneumonie může být snadno zaměnitelný s jinými stavy, jako je edém plic, atelektáza nebo plicní fibróza.
2. **Lidský faktor:** Únava lékařů při vyhodnocování velkého množství snímků (např. během epidemií) zvyšuje riziko přehlédnutí nálezu (falešná negativita).
3. **Dostupnost expertů:** V rozvojových zemích nebo odlehlých oblastech může být nedostatek kvalifikovaných radiologů kritický.

Právě tyto limitace otevírají prostor pro aplikaci systémů počítačového vidění a umělé inteligence. Algoritmy, jako jsou konvoluční neuronové sítě (CNN), a v kontextu této práce i hybridní kvantové sítě, mají potenciál sloužit jako „druhý pár očí“, který dokáže konzistentně detekovat jemné vzory v obraze, jež mohou lidskému oku uniknout.

2.1.4 Problém mizejícího gradientu a degradace

S rostoucí hloubkou neuronových sítí se historicky objevoval problém tzv. mizejícího gradientu (vanishing gradient). Při zpětném šíření chyby (backpropagation) přes mnoho vrstev se derivace postupně zmenšovaly k nule, což znemožňovalo efektivní učení prvních vrstev sítě. Paradoxně, přidávání dalších vrstev vedlo k horším výsledkům nejen na testovací, ale i na trénovací sadě – tento jev je znám jako problém degradace (degradation problem).

2.2 Statistické vyhodnocení výsledků

Při hodnocení modelů strojového učení, obzvláště v medicínské doméně, nestačí spoléhat pouze na bodové odhady metrik (jako je jedna hodnota přesnosti nebo AUC na testovací sadě). Abychom mohli s jistotou prohlásit, že rozdíly mezi klasickým a hybridním kvantovým modelem nejsou dány pouze náhodným rozdělením testovacích dat, byla do metodiky zařazena rigorózní statistická analýza zahrnující intervaly spolehlivosti a testy statistické významnosti.

2.2.1 Bootstrap intervaly spolehlivosti

Pro určení nejistoty hlavních metrik (Accuracy, F1-skóre, AUC-ROC) byl použit neparametrický *bootstrap*. Tato metoda spočívá v opakovaném náhodném výběru vzorků z testovací sady s vracením (resampling with replacement).

V této práci byl proces opakován pro $B = 1000$ iterací. Pro každou iteraci byla vypočtena sledovaná metrika, čímž vzniklo empirické rozdělení dané metriky. Následně byl určen 95% interval spolehlivosti (Confidence Interval, CI) pomocí 2,5. a 97,5. percentilu tohoto rozdělení. Získaný interval nám udává rozmezí, ve kterém se s 95% pravděpodobností nachází skutečná hodnota metriky pro populaci, z níž testovací data pocházejí.

2.2.2 McNemarův test statistické významnosti

Pro přímé porovnání predikční úspěšnosti dvou modelů (např. klasického baseline modelu a kvantového VQC) na stejném testovacím souboru byl použit McNemarův test. Na rozdíl od běžného t-testu je McNemarův test určen pro párová nominální data a soustředí se výhradně na vzorky, kde se modely neshodují.

Nechť b je počet vzorků, které klasický model klasifikoval správně a kvantový chybně, a c je počet vzorků, které klasický model klasifikoval chybně a kvantový správně. Testovací statistika s korekcí na kontinuitu je definována jako:

$$\chi^2 = \frac{(|b - c| - 1)^2}{b + c} \quad (2.1)$$

Tato statistika má asymptoticky chí-kvadrát rozdělení s jedním stupněm volnosti. Pokud je výsledná p-hodnota menší než zvolená hladina významnosti $\alpha = 0,05$, je zamítnuta nulová hypotéza o stejné predikční úspěšnosti obou modelů a lze prohlásit zjištěný rozdíl (např. propad přesnosti u NISQ simulace) za statisticky signifikantní.

2.3 Úvod do kvantového počítání

Zatímco klasické počítače, na kterých běží tradiční neuronové sítě, zpracovávají informace v bi-tech, kvantové počítače využívají principů kvantové mechaniky, jako je superpozice a provázání (entanglement). Základní informační jednotkou je kvantový bit, zkráceně **qubit** [5].

2.3.1 Qubit a superpozice

Klasický bit se může nacházet pouze v jednom ze dvou diskrétních stavů: 0 nebo 1. Naproti tomu qubit může existovat v tzv. superpozici obou těchto stavů současně. Matematicky qubit reprezentujeme jako vektor v dvourozměrném Hilbertově prostoru. Používáme k tomu Diracovu „ket“ notaci:


$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle \quad (2.2)$$

kde $|0\rangle$ a $|1\rangle$ jsou báze stavy (odpovídající klasické 0 a 1) a koeficienty $\alpha, \beta \in \mathbb{C}$ jsou komplexní amplitudy pravděpodobnosti. Pro tyto amplitudy musí platit normalizační podmínka:

$$|\alpha|^2 + |\beta|^2 = 1 \quad (2.3)$$

To znamená, že pokud změříme qubit ve stavu superpozice, „zhrouť“ se do stavu $|0\rangle$ s pravděpodobností $|\alpha|^2$ nebo do stavu $|1\rangle$ s pravděpodobností $|\beta|^2$. Právě tato pravděpodobnostní povaha je zásadním rozdílem oproti deterministickému klasickému bitu.

2.3.2 Blochova sféra



Obr. 2.1: Geometrická reprezentace stavu qubitu na Blochově sféře.

Pro vizualizaci stavu jednoho qubitu se často využívá geometrická reprezentace zvaná Blochova sféra (Obrázek 2.1). Libovolný čistý stav qubitu lze zapsat pomocí úhlů θ a ϕ jako bod na povrchu koule o poloměru 1:

$$|\psi\rangle = \cos\left(\frac{\theta}{2}\right)|0\rangle + e^{i\phi}\sin\left(\frac{\theta}{2}\right)|1\rangle \quad (2.4)$$

Tato reprezentace je klíčová pro pochopení fungování kvantových neuronových sítí. Trénování sítě v podstatě znamená hledání optimálních rotací stavového vektoru na této sféře tak, aby při měření dopadl výsledek do požadované třídy (např. „pneumonie“).

2.3.3 Kvantová hradla (Quantum Gates)

Stejně jako klasické počítače používají logická hradla (AND, OR, NOT), kvantové algoritmy jsou sestaveny z kvantových hradel, která provádějí unitární operace na qubitech.

- **Hadamardovo hradlo (H):** Vytváří superpozici. Mění stav $|0\rangle$ na $\frac{|0\rangle+|1\rangle}{\sqrt{2}}$, což dává 50% šanci na změření 0 nebo 1.
- **Rotační hradla (R_x, R_y, R_z):** Tato hradla otáčejí qubit kolem os x, y nebo z na Blochově sféře o určitý úhel. V kontextu variačních kvantových obvodů (VQC) jsou právě úhly těchto rotací těmi parametry (ahami), které se síť učí během tréninku.
- **CNOT (Controlled-NOT):** Dvouqubitové hradlo, které je nezbytné pro vytvoření kvantového provázání. Pokud je řídicí qubit ve stavu $|1\rangle$, otočí cílový qubit (operace NOT).

2.3.4 Kvantové provázání (Entanglement)

Provázání je jev, kdy se stavy dvou nebo více qubitů stanou na sobě závislými takovým způsobem, že stav celého systému nelze popsat pouze popisem stavů jednotlivých qubitů. Pokud změříme jeden z provázaných qubitů, okamžitě tím získáme informaci o druhém, a to bez ohledu na vzdálenost mezi nimi. V strojovém učení umožňuje entanglement zachytit složité korelace mezi daty, které jsou pro klasické modely výpočetně náročné.

2.4 Kvantové strojové učení (QML)

Kvantové strojové učení je interdisciplinární oblast, která zkoumá možnosti využití kvantových algoritmů k vylepšení metod umělé inteligence. V kontextu současné éry NISQ se jako nejslibnější směr jeví tzv. hybridní kvantově-klasické algoritmy. Tyto algoritmy nespolehnají čistě na kvantový počítač, ale efektivně kombinují silné stránky klasických procesorů (CPU/GPU) a kvantových procesorů (QPU) [6].

2.4.1 Hybridní architektura

V hybridním modelu, který je předmětem této práce, je výpočetní proces rozdělen do dvou fází:

1. **Klasická část (Feature Extraction):** Hluboká konvoluční síť (v tomto případě ConvNeXt-Tiny) zpracovává vysokorozměrná vstupní data (rentgenové snímky s miliony pixelů). Jejím úkolem je redukovat dimenzi dat a extrahovat z nich kompaktní vektor příznaků (feature vector).
2. **Kvantová část (Classification):** Tento vektor příznaků slouží jako vstup do kvantového obvodu. QPU provede výpočet v Hilbertově prostoru a vrátí výsledek (pravděpodobnost tříd), který je následně využit pro výpočet chybové funkce.

Klíčovým mechanismem je zpětné šíření chyby (backpropagation). Gradienty jsou vypočítávány na klasickém počítači, avšak pro optimalizaci parametrů v kvantovém obvodu se využívá specifických metod, jako je např. *Parameter Shift Rule* (na reálném hardwaru) nebo přímá diferenciace simulace [7].

2.4.2 Kódování dat (Data Encoding)

Aby mohl kvantový obvod zpracovat data z klasické sítě, musí být klasický vektor $\mathbf{x} = (x_1, \dots, x_N)$ převeden do kvantového stavu $|\psi_{\mathbf{x}}\rangle$. Tento proces, nazývaný *State Preparation* nebo *Embedding*, je kritickou částí algoritmu, neboť ovlivňuje expresivitu celého modelu. Mezi nejčastěji používané metody patří:

- **Angle Encoding (Úhlové kódování):** Každá hodnota x_i ze vstupního vektoru je použita jako úhel rotace pro jedno kvantové hradlo. Vyžaduje N qubitů pro N příznaků.
- **Amplitude Encoding (Amplitudové kódování):** Data jsou zakódována do amplitud kvantového stavu. Vektor $\mathbf{x}$ je normalizován a jeho prvky odpovídají amplitudám pravděpodobnosti bázevých stavů:

$$|\psi\rangle = \sum_{i=1}^{2^n} x_i |i\rangle \quad (2.5)$$

Tato metoda je exponenciálně úsporná (pro N příznaků stačí $\log_2 N$ qubitů), a proto byla zvolena pro tuto práci [8].

2.4.3 Variační kvantové obvody (VQC)

Variační kvantový obvod (Variational Quantum Circuit, VQC) plní v hybridním modelu roli, kterou v klasických sítích zastávají plně propojené vrstvy. Jedná se o parametrický kvantový obvod $U(\theta)$, kde θ představuje sadu nastavitelných parametrů (úhlů rotací). Matematicky lze operaci VQC popsat jako unitární transformaci vstupního stavu $|\psi_x\rangle$, následovanou měřením:

$$f(\mathbf{x}, \theta) = \langle \psi_x | U^\dagger(\theta) M U(\theta) | \psi_x \rangle \quad (2.6)$$

kde M je operátor měření (pozorovatelná veličina, typicky Pauli-Z operátor). Trénink sítě pak spočívá v hledání takových parametrů θ , které minimalizují chybovou funkci na trénovací množině.

2.4.4 Problém barren plateaus

Jedním z nejvýznamnějších teoretických i praktických limitů současných variačních kvantových algoritmů (VQA) je jev označovaný jako *barren plateaus*. Při trénování parametrizovaných kvantových obvodů pomocí gradientních metod se může stát, že krajina nákladové funkce je téměř všude extrémně plochá: změna libovolného parametru vede jen k zanedbatelné změně hodnoty chybové funkce. V takové situaci gradienty mířící k optimu prakticky mizí a optimalizace se stává numericky neproveditelnou, zejména pro větší počty qubitů.

Formálně se barren plateaus popisují pomocí rozptylu gradientů nákladové funkce $C(\theta)$ podle jednotlivých parametrů θ_i . Pro jednoduchost uvažujme jeden parametr θ_i ; zajímá nás náhodná proměnná $\partial_{\theta_i} C(\theta)$, kde θ jsou náhodně inicializované parametry ansatzu. V mnoha situacích, zejména pro hluboké „náhodné“ obvody s globální nákladovou funkcí, lze ukázat, že rozptyl gradientu klesá alespoň exponenciálně s počtem qubitů n :

$$\text{Var}[\partial_{\theta_i} C(\theta)] = \mathcal{O}(2^{-n}). \quad (2.7)$$

V limitě velkého n se tak téměř všechny gradienty koncentrují v okolí nuly a jakékoli praktické gradientní učení se stává nereálným.

Sjednocená teorie barren plateaus ukazuje, že tato exponenciální závislost vzniká kombinací tří faktorů: struktury ansatzu (hloubka, topologie propletení), volby nákladové funkce (globální vs. lokální) a způsobu inicializace parametrů. Obecně platí, že hluboké obvody s globální nákladovou funkcí (např. průměrná energie přes celý systém) a náhodnou inicializací mají tendenci generovat barren plateaus, zatímco mělké, lokálně strukturované obvody s lokálními nákladovými funkcemi se tomuto jevu do jisté míry vyhýbají.

V reakci na tento problém vznikla celá řada koncepčně odlišných strategií mitigace barren plateaus:

- **Mělké a lokální ansatze:** Namísto hlubokých obvodů s globálním propletením se používají mělké architektury, kde každý qubit interaguje pouze se svými nejbližšími sousedy (např. lineární nebo kruhové řetězce CNOT hradel). Takové ansatze mají menší efektivní hloubku a empiricky vykazují pomalejší útlum gradientů.
- **Lokální nákladové funkce:** Místo globálních observablí (součet po všech qubitech) se používají lokální cost funkce definované na podmnožinách qubitů (např. jen na jednom nebo několika měřených qubitech). To snižuje stupeň „průměrování“ přes Hilbertův prostor a udržuje rozptyl gradientů na polynomiální úrovni.

- **Speciální inicializace:** Namísto zcela náhodné inicializace parametrů lze využít strategie, které začínají v okolí jednoduchých (např. produktových) stavů nebo v blízkosti identity. Tím se obvod vyhne oblasti parametrického prostoru, kde již implementuje téměř Haarovsky náhodnou unitární transformaci, a gradienty jsou v počátečních fázích učení lépe „rozlišitelné“.
- **Fyzikálně inspirované architektury:** Další možností je navrhnout ansatz tak, aby respektoval konkrétní strukturu řešeného problému – například Hamiltonian variational ansatz nebo obvody založené na známých symetriích systému. Tyto architektury typicky nepotřebují univerzální expresivitu, ale jsou lépe přizpůsobeny dané úloze a mohou se tak vyhnout oblastem parametrického prostoru, kde dochází k barren plateaus.

V praxi se často kombinuje několik z těchto přístupů: volí se mělký, lokálně proplétající ansatz, vhodně se inicializují parametry a používá se nákladová funkce založená na lokálních měřeních. Teoretické i numerické studie ukazují, že takové nastavení výrazně zlepšuje trénovatelnost variačních kvantových obvodů a představuje v současnosti nejrealističtější cestu k využití VQC v éře NISQ.

2.4.5 Data re-uploading ansatz

V klasických variačních kvantových obvodech se vstupní data obvykle zakódují do kvantového stavu pouze jednou na začátku obvodu (např. pomocí amplitudového nebo úhlového kódování). Následně je aplikována sekvence parametrizovaných hradel, která stav transformují před samotným měřením. Nedávné studie v oblasti kvantového strojového učení však ukazují, že tento přístup fundamentálně omezuje expresivitu (vyjadřovací schopnost) modelu. Kvantové modely lze totiž matematicky chápat jako Fourierovy řady, kde jednorázové zakódování dat umožňuje obvodu naučit se pouze nízkofrekvenční závislosti. Pro zachycení složitých, vysoce nelineárních vzorů v datech – což je u medicínských obrazů nezbytné – je jednorázové vložení informace nedostačující.

Tento problém elegantně řeší technika zvaná *data re-uploading*, kterou představil Pérez-Salinas a kolektiv v roce 2020 [9]. Inspirací pro tuto metodu jsou klasické hluboké neuronové sítě, kde nelineární aktivační funkce oddělují jednotlivé lineární transformace, čímž síť získává svou obrovskou kapacitu. V kvantovém prostředí je však veškerý vývoj uzavřeného systému (vyjma samotného měření) striktně lineární a unitární. Koncept data re-uploading obchází toto omezení tím, že klasická vstupní data opakovaně vkládá (zakódovává) do kvantového obvodu v každé jeho vrstvě.

Matematicky lze jednu vrstvu takového obvodu popsat jako aplikaci datově závislého kódovacího bloku $S(x)$ a parametrizovaného bloku $U(\theta)$. Celková unitární transformace obvodu o L vrstvách má pak tvar:

$$U_{\text{total}}(x, \theta) = U_L(\theta_L)S(x) \cdots U_2(\theta_2)S(x)U_1(\theta_1)S(x) \quad (2.8)$$

Opakovaným vkládáním dat $S(x)$ v každé vrstvě získává model přístup k vyšším harmonickým frekvencím Fourierovy řady. Pérez-Salinas teoreticky dokázal, že i jednokubitový klasifikátor s využitím data re-uploadingu dokáže aproximovat libovolnou spojitou funkci, čímž se stává univerzálním aproximátorem.

V kontextu této práce znamená implementace data re-uploadingu zásadní zvýšení kapacity sítě bez nutnosti přidávat další qubity. Ačkoliv se tím lineárně zvyšuje hloubka obvodu, prokazatelně se tím zlepšuje schopnost modelu učit se komplexní rozhodovací hranice mezi třídami

normálního nálezu a pneumonie, a to i při zachování extrémně nízkého počtu trénovatelných parametrů.

2.4.6 Škálování vstupních dat: Fourierova frekvenční analýza

Při implementaci data re-uploading ansatzu je klíčové pochopit, že kvantový obvod s rotačními hradly (např. $R_y(x_i)$) se matematicky chová jako Fourierova řada. Základní problém spočívá v tom, že přímé vložení latentního vektoru $\mathbf{x}$ do rotačního hradla umožňuje obvodu reprezentovat pouze jednoduché sinusové a kosinusové vlny – obvod má přístup pouze k nejnižším harmonickým frekvencím.

Pro zachycení ostrých, komplexních rozhodovacích hranic mezi třídami „Pneumonie“ a „Normální“ je tento přístup nedostatečný. Proto byl zaveden naučitelný škálovací parametr pro každou dimenzi vstupních dat. Místo jednoduchého zakódování $R_y(x_i)$ je použito:

$$R_y(w_i \cdot x_i) \quad (2.9)$$

kde w_i je trénovatelný parametr, který se model učí během optimalizace. Tato na první pohled jednoduchá modifikace má fundamentální důsledky pro expresivitu modelu:

Fyzikální interpretace: Naučením parametrů w_i se kvantový obvod učí „frekvenci“ dat. Parametr w_i škáluje vstupní hodnotu x_i před vstupem do rotačního hradla, čímž efektivně mění úhlovou frekvenci oscilace qubitového stavu na Blochově sféře. Tím se VQC přirozeně stává extraktorem vysokofrekvenčních příznaků, což činí data re-uploading exponenciálně expresivnější.

Matematicky, naučitelné škálování umožňuje obvodu přistupovat k vyšším harmonickým členům Fourierovy řady:

$$f(x) = \sum_{k=0}^{\infty} a_k \sin(k \cdot w \cdot x + \phi_k) \quad (2.10)$$

Bez naučitelného škálování je model omezen pouze na $k = 0, 1$. Se škálovacími parametry w_i se model může naučit optimální hodnoty k , které odpovídají skutečné frekvenční struktuře klasifikovaných rentgenových snímků. V kontextu detekce pneumonie to znamená, že model může detekovat jemné texturní vzory charakteristické pro lobární konsolidaci (bakteriální pneumonie) nebo difúzní intersticiální vzory (virová pneumonie) s vyšší přesností.

V předložené implementaci je škálovací parametr w_i inicializován na hodnotu 1,0 a trénován společně s ostatními parametry ansatzu pomocí Adam optimizery. Tato volba zajišťuje, že na začátku tréninku se obvod chová jako standardní data re-uploading bez škálování, a postupně se přizpůsobuje optimální frekvenční reprezentaci dat.

2.4.7 Kvantifikace expresivity a schopnosti provázání

Při návrhu variačních kvantových obvodů je jedním z nejnáročnějších úkolů volba vhodné architektury (ansatzu) a její hloubky (počtu vrstev L). Příliš mělký obvod nedokáže zachytit složité nelineární závislosti v datech, zatímco příliš hluboký obvod je náchylný k problému mizejících gradientů a v éře NISQ kumuluje neakceptovatelné množství hardwarového šumu. Pro vyhnutí se zdoluhavému a neefektivnímu hledání hyperparametrů metodou pokus-omyl jsou ke zhodnocení ansatzu využity rigorózní metriky, které představili Sim a kol. v roce 2019 [10].

Expresivita (Expressibility)

Expresivita kvantového obvodu definuje jeho schopnost prozkoumávat stavový prostor (Hilbertův prostor). Vysoce expresivní obvod dokáže při rovnoměrném vzorkování svých parametrů θ vygenerovat sadu kvantových stavů, která rovnoměrně pokrývá celou Blochovu sféru (případně její vícerozměrný ekvivalent).

Pro kvantifikaci expresivity se porovnává rozdělení pravděpodobností fidelit (překryvů) náhodně generovaných párů stavů z testovaného obvodu, označené jako $P_{\text{ansatz}}(F)$, s teoretickým uniformním rozdělením kvantových stavů, tzv. Haarovou mírou $P_{\text{Haar}}(F)$. Odchylka těchto dvou rozdělení se měří pomocí Kullback-Leiblerovy (KL) divergence:

$$Expr = D_{KL}(P_{\text{ansatz}} \parallel P_{\text{Haar}}) = \int P_{\text{ansatz}}(F) \log \left(\frac{P_{\text{ansatz}}(F)}{P_{\text{Haar}}(F)} \right) dF \quad (2.11)$$

Platí, že **čím nižší je hodnota KL divergence, tím vyšší je expresivita obvodu**. Hodnota blízká nule znamená, že obvod je schopen aproximovat libovolný unitární operátor.

Schopnost provázání (Entangling Capability)

Druhou klíčovou vlastností je schopnost obvodu vytvářet kvantové provázání (entanglement) mezi jednotlivými qubity. Entanglement je fundamentální kvantový zdroj, který umožňuje obvodu zachytit silné korelace mezi různými vstupními příznaky (například závislosti mezi různými pixely na rentgenovém snímku).

Tato vlastnost se nejčastěji kvantifikuje pomocí Meyer-Wallachovy (MW) míry, označené jako Q . Pro neseperabilní (čistě provázaný) stav typu Bellových stavů je $Q = 1$, zatímco pro plně separabilní stavy (bez provázání) je $Q = 0$. Schopnost provázání daného ansatzu je definována jako průměrná Meyer-Wallachova míra přes všechny stavy vygenerované náhodným vzorkováním parametrů:

$$Ent = \mathbb{E}_{\theta} [Q(|\psi_{\theta}\rangle)] \quad (2.12)$$

V experimentální části této práce jsou obě metriky vypočítány pro námi navržený *data re-uploading* ansatz s hloubkou $L \in \{1, 2, 3, 4\}$. Tato analýza slouží jako teoretické opodstatnění pro finální volbu počtu vrstev, která zaručuje dostatečnou klasifikační kapacitu modelu při minimalizaci jeho celkové hardwarové hloubky před případným budoucím během na procesorech IBM.

2.4.8 Autoenkodéry pro nelineární redukci dimenzionality

Autoenkodér (Autoencoder, AE) je typ neuronové sítě navržený pro učení efektivních kódování (representací) vstupních dat v nesupervizovaném režimu. Na rozdíl od lineárních metod redukce dimenzionality, jako je analýza hlavních komponent (PCA), autoenkodér využívá nelineární aktivační funkce, což mu umožňuje zachytit složitě, nelineární závislosti v datech, které by lineární projekce nenávratně ztratila [11].

Architektura enkodér-dekodér

Autoenkodér se skládá ze dvou hlavních komponent:

1. **Enkodér (Encoder):** Funkce $f_\theta : \mathbb{R}^D \rightarrow \mathbb{R}^d$, která mapuje vstupní vektor $\mathbf{x} \in \mathbb{R}^D$ do latentního (skrytého) prostoru nižší dimenze $d < D$. Latentní reprezentace $\mathbf{z} = f_\theta(\mathbf{x})$ slouží jako komprimovaný “otisk” vstupních dat.
2. **Dekodér (Decoder):** Funkce $g_\phi : \mathbb{R}^d \rightarrow \mathbb{R}^D$, která se snaží z latentní reprezentace $\mathbf{z}$ rekonstruovat původní vstup $\hat{\mathbf{x}} = g_\phi(\mathbf{z}) \approx \mathbf{x}$.

Celý model je trénován minimalizací rekonstrukční chyby, typicky střední kvadratické chyby (MSE):

$$\mathcal{L}_{\text{AE}}(\theta, \phi) = \frac{1}{N} \sum_{i=1}^N \|\mathbf{x}_i - g_\phi(f_\theta(\mathbf{x}_i))\|^2 \quad (2.13)$$

Proč nelineární komprese převyšuje PCA

PCA hledá lineární projekci dat do podprostoru, který maximalizuje zachovaný rozptyl. Tato metoda je optimální pouze tehdy, pokud data leží na lineárním podprostoru. V případě vysoce nelineárních dat, jako jsou příznaky extrahované z medicínských obrazů konvoluční sítí, PCA nutně ztrácí informaci, která se nachází mimo nalezený lineární podprostor.

Autoenkodér naproti tomu může aproximovat libovolnou spojitou nelineární transformaci díky univerzální aproximační větě pro neuronové sítě [12]. Díky tomu je schopen naučit se takovou kompresi, která zachovává nikoliv pouze maximální rozptyl, ale specifické struktury a vzory v datech, které jsou relevantní pro následnou klasifikaci. V kontextu této práce to znamená, že autoenkodér může zachovat diskriminační signál pro pneumonii i při redukci z 768 na pouhých 64 dimenzí – což je přesně počet potřebný pro amplitudové kódování na 6 qubitech.

Regularizace a architektura použitého autoenkodéru

Aby autoenkodér nenaučil triviální identitu (kdy by enkodér pouze zkopíroval vstup a dekodér by jej beze změny reprodukoval), je nutné zavést regularizační mechanismy. V této práci je použita kombinace tří přístupů:

- **Bottleneck (úzké hrdlo):** Latentní prostor má dimenzi $d = 64$, což je výrazně méně než vstupní dimenze $D = 768$. Toto nucené omezení nutí síť naučit se smysluplnou kompresi.
- **Dropout:** Během tréninku je náhodně deaktivována část neuronů (s pravděpodobností 0,2), což zabraňuje ko-adaptaci a nucuje síť naučit se robustnější reprezentace.
- **Batch Normalizace:** Stabilizuje trénink normalizací aktivací v každé vrstvě, což umožňuje použití vyšších rychlostí učení a rychlejší konvergenci.

Architektura enkodéru v této práci je navržena jako:

$$\mathbf{z} = \text{Linear}_{64} \left(\sigma \left(\text{BN}_{256}(\text{Linear}_{256}(\mathbf{x})) \right) \right), \quad (2.14)$$

kde σ je aktivační funkce LeakyReLU s parametrem $\alpha = 0,2$ a BN_{256} značí batch normalizaci nad 256 neurony. Dekodér má symetrickou architekturu ($64 \rightarrow 256 \rightarrow 768$) a po tréninku je zahazen – pro redukci nových dat slouží pouze enkodér.

2.4.9 Doménová adaptace a adverzální učení (DANN)

Při aplikaci modelů strojového učení v medicínské diagnostice se často setkáváme s problémem *dataset shiftu* (posunu distribuce): data, na kterých je model trénován (zdrojová doména), mají odlišnou statistickou distribuci než data, na kterých má model predikovat v produkci (cílová doména). Tento jev je obzvláště výrazný u medicínských obrazů, kde se mohou lišit typy přístrojů, expoziční protokoly, věková struktura pacientů nebo poměr zdravých a patologických nálezů [13].

Formalizace problému

Nechť $\mathcal{D}_S$ je zdrojová (trénovací) doména s distribucí $P_S(\mathbf{x}, y)$ a $\mathcal{D}_T$ je cílová (testovací) doména s distribucí $P_T(\mathbf{x}, y)$. Pokud $P_S \neq P_T$, model naučený na $\mathcal{D}_S$ nemusí dobře generalizovat na $\mathcal{D}_T$. V případě *covariate shift* se liší marginální distribuce vstupů $P_S(\mathbf{x}) \neq P_T(\mathbf{x})$, zatímco podmíněná distribuce labelů $P(y | \mathbf{x})$ zůstává stejná.

V této práci byl identifikován významný dataset shift: trénovací sada obsahuje 74,2 % případů pneumonie, zatímco testovací sada pouze 62,5 %. Tento posun o 11,7 procentního bodu může vést k tomu, že model naučený na trénovací distribuci bude mít tendenci nadhodnocovat pravděpodobnost pneumonie i u zdravých snímků v testovací sadě.

Domain-Adversarial Neural Network (DANN)

Jedním z nejúspěšnějších přístupů k mitigaci dataset shiftu je *Domain-Adversarial Neural Network* (DANN), kterou představili Ganin a kol. v roce 2016 [14]. DANN spadá do kategorie *unsupervised domain adaptation*, kdy model během tréninku pozoruje neoznačená data z cílové domény, avšak bez přístupu k jejich labelům.

Architektura DANN se skládá ze tří komponent:

1. **Extraktor příznaků** G_f : Sdílená část modelu (v tomto případě ConvNeXt-Tiny), která transformuje vstup $\mathbf{x}$ do příznakové reprezentace $\mathbf{f} = G_f(\mathbf{x})$.
2. **Prediktor labelu** G_y : Klasifikační hlava, která z příznaků $\mathbf{f}$ predikuje label $\hat{y} = G_y(\mathbf{f})$. Trénována pouze na zdrojových datech.
3. **Doménový diskriminátor** G_d : Klasifikátor, který se snaží rozlišit, zda příznak $\mathbf{f}$ pochází ze zdrojové domény (label 0) nebo z cílové domény (label 1).

Gradient Reversal Layer (GRL)

Klíčovým mechanismem DANN je *Gradient Reversal Layer* (GRL), která se vkládá mezi extraktor příznaků G_f a doménový diskriminátor G_d . Během přímého průchodu (forward pass) se GRL chová jako identita:

$$\text{GRL}(\mathbf{f}) = \mathbf{f}. \quad (2.15)$$

Během zpětného šíření chyby (backward pass) však násobí gradient zápornou konstantou $-\lambda$:

$$\frac{\partial \text{GRL}(\mathbf{f})}{\partial \mathbf{f}} = -\lambda \cdot \mathbf{I}, \quad (2.16)$$

kde $\mathbf{I}$ je jednotková matice a λ je hyperparametr řízený silou adverzálního efektu.

Tento mechanismus vytváří *minimax hru* mezi extraktorem příznaků a doménovým diskriminátorem: diskriminátor se snaží co nejlépe rozlišit zdrojovou a cílovou doménu, zatímco extraktor příznaků (přijímající záporný gradient) se naopak snaží produkovat takové reprezentace, které jsou pro diskriminátor nerozlišitelné. Výsledkem jsou *doménově-invariantní příznaky*, které obsahují informaci relevantní pro klasifikaci, ale nikoliv pro identifikaci domény.

Celková ztráta a tréninkový proces

Celková ztráta DANN je kombinací tří složek:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{label}} - \lambda (\mathcal{L}_{\text{domain}}^S + \mathcal{L}_{\text{domain}}^T), \quad (2.17)$$

kde $\mathcal{L}_{\text{label}}$ je binární cross-entropy pro predikci pneumonie (pouze na zdrojových datech) a $\mathcal{L}_{\text{domain}}^S, \mathcal{L}_{\text{domain}}^T$ jsou doménové cross-entropy pro zdrojovou a cílovou doménu. Parametr λ je postupně navyšován podle vzorce:

$$\lambda(p) = \frac{2}{1 + e^{-10p}} - 1, \quad p = \frac{\text{current_step}}{\text{total_steps}}, \quad (2.18)$$

což zajišťuje, že v raných fázích tréninku (kdy jsou váhy ještě náhodné) je vliv GRL minimální ($\lambda \approx 0$), což umožňuje modelu nejprve naučit smysluplnou klasifikaci. Postupně se λ blíží k 1 a adverzální efekt sílí.

Proč nejde o data leakage

V rámci transduktivní unsupervised domain adaptation je přípustné, aby model pozoroval neoznačená data z cílové domény. Doménový diskriminátor přijímá pouze informaci o příslušnosti ke zdrojové či cílové doméně (binární label 0/1), nikoliv diagnostické labely Normal/Pneumonia. Konvoluční extraktor se tedy učí přizpůsobit pixelovým charakteristikám cílové domény (kontrast, expozice, kalibrace přístroje), aniž by měl přístup k informaci o skutečné diagnóze pacientů v testovací sadě. Validace nemůže sloužit jako cílová doména, protože vznikla stratifikovaným rozdělením z trénovacích dat a sdílí tedy stejný posun tříd.

Kapitola 3

Cíle práce

Hlavním cílem této práce je navrhnout, implementovat a experimentálně ověřit architekturu hybridní kvantově-klasické neuronové sítě pro medicínskou diagnostiku. Konkrétně se práce zaměřuje na detekci pneumonie z rentgenových snímků hrudníku v kontextu současných hardwarových omezení éry NISQ (*Noisy Intermediate-Scale Quantum*).

Na základě teoretické rešerše a analýzy problému byly stanoveny následující dílčí cíle:

1. **Implementace hybridního modelu:** Vytvořit funkční model, který propojuje moderní klasickou konvoluční síť ve funkci extraktoru příznaků s variačním kvantovým obvodem (VQC), jenž bude plnit roli klasifikátoru.
2. **Optimalizace pro NISQ:** Navrhnout vhodné kódování klasických dat do kvantových stavů (*data encoding*) a strukturu kvantového obvodu (*ansatzu*) tak, aby byl model trénovatelný na simulátoru kvantového počítače s omezeným počtem qubitů a s ohledem na budoucí nasazení na reálném hardwaru.
3. **Experimentální srovnání:** Porovnat výkonnost navrženého hybridního modelu s referenčním čistě klasickým modelem nad stejnými příznaky z ConvNeXt-Tiny redukovánými autoenkodérem. Referenční model je realizován jako vícevrstvý perceptron (klasický neuronový klasifikátor) trénovaný na 64-rozměrných vektorech příznaků bez použití kvantového obvodu.
4. **Analýza efektivity:** Vyhodnotit, zda zapojení kvantové vrstvy přináší výhodu v podobě snížení počtu trénovatelných parametrů v rozhodovací části modelu a jak návrh kvantového obvodu ovlivňuje konvergenci a stabilitu trénování.

Výzkumné otázky a hypotéza

V souladu s vytýčenými cíli si práce klade za úkol ověřit následující hypotézu:

Hybridní kvantově-klasická neuronová síť dokáže při detekci pneumonie dosáhnout srovnatelné klasifikační přesnosti jako vhodně zvolený čistě klasický model nad stejnými příznaky, a to při využití řádově nižšího počtu trénovatelných parametrů v rozhodovací (klasifikační) části.

Práce dále hledá odpověď na otázku, zda jsou současné metody kvantového strojového učení (QML) dostatečně robustní pro zpracování reálných biomedicínských obrazových dat s vysokým rozlišením, nebo zda jejich aplikaci v praxi prozatím brání především hardwarové limity (šum a dekoherence) kvantových procesorů.


Kapitola 4

Metodika a experimentální část

Tato kapitola popisuje použitý datový soubor, metody předzpracování obrazových dat včetně pokročilé augmentace a detailní návrh experimentální architektury. Dále jsou specifikovány tréninkové parametry a softwarové prostředí.

4.1 Navržená experimentální architektura

Jádrem experimentální části je modulární pipeline, která zajišťuje objektivní srovnání klasických a kvantových přístupů nad identickým prostorem příznaků. Schéma celkové architektury je znázorněno na Obrázku 4.1.



Obr. 4.1: Schéma navržené hybridní architektury. Klasická extrakce příznaků je sdílená, na ni navazují dva nezávislé klasifikační modely (VQC a MLP), které jsou následně statisticky evaluovány.

Vstupní rentgenové snímky nejprve procházejí fází robustní augmentace a jsou zpracovány předtrénovanou konvoluční sítí ConvNeXt-Tiny, která je následně adaptována pomocí doménově-adverzálního učení (DANN). Tím se zajišťuje, že extrahované příznaky jsou invariantní vůči posunu mezi trénovací a testovací distribucí. Takto adaptované vektory jsou následně redukovány pomocí autoenkodéru na 64 dimenzí a L_2 -normalizovány, čímž vzniká finální prostor příznaků vhodný pro kvantové amplitudové kódování.

Na tento sdílený klasický základ navazují dvě nezávislé klasifikační větve:


1. **Klasický MLP (Baseline):** Tradiční vícevrstvý perceptron, který slouží jako referenční model zastupující vyspělé klasické metody hlubokého učení.
2. **VQC (Variální kvantový klasifikátor):** Hlavní zkoumaný hybridní model. Využívá pokročilý *data re-uploading* ansatz pro maximalizaci expresivity omezeného počtu šesti qubitů. Tento model je evaluován na ideálním simulátoru.

Takto navržená architektura umožňuje objektivně posoudit, zda a do jaké míry mohou kvantové klasifikátory v éře NISQ konkurovat klasickým sítím nad stejnou extrahovanou informací. Striktní oddělení sdílené příznakové části a rozhodovací části izoluje vliv samotných kvantových algoritmů.

4.2 Datový soubor a explorační analýza dat

Pro trénování a testování modelu byl využit veřejně dostupný dataset *Chest X-Ray Images (Pneumonia)*, který sestavil Paul Mooney z dat pocházejících z Guangzhou Women and Children's Medical Center. Dataset obsahuje celkem 5 856 rentgenových snímků hrudníku v předozadní projekci, jež byly pořízeny u pediatrických pacientů ve věku přibližně 1 až 5 let.

Snímky jsou primárně rozděleny do dvou tříd: *Normal* (zdravý plicní parenchym) a *Pneumonia* (zápal plic). V rámci explorační analýzy (viz Obrázek 4.2) bylo zjištěno, že třída s pneumonií obsahuje vizuálně zcela odlišné subtypy onemocnění (bakteriální lobární konsolidace vs. virové difúzní intersticiální infiltráty), což klade vysoké nároky na expresivitu extraktoru příznaků, který musí tyto variabilní vzory rozpoznat jako jednu nadřazenou třídu.



Obr. 4.2: Ukázka variabilních projevů v datasetu. Zleva: zdravý pacient, bakteriální pneumonie (zřetelná ložisková konsolidace) a virová pneumonie (difúzní vzor infiltrátů).

4.2.1 Struktura datasetu a patologie pneumonie

Použitý dataset hrudních skiagramů (RTG) není omezen pouze na základní binární rozdělení na zdravé pacienty (*Normal*) a pacienty se zápalom plic (*Pneumonia*). Třída patologických nálezů se dále přirozeně dělí na základě mikrobiologického původce onemocnění, a to především na virovou a bakteriální pneumonii.

Toto podrobnější dělení je z hlediska přesné diagnostiky a trénování modelů strojového učení klíčové, neboť virová a bakteriální pneumonie se na rentgenových snímcích často vizuálně projevují odlišnými rysy:

- **Bakteriální pneumonie:** Typicky se projevuje fokálními lobárními konsolidacemi, tedy jasnějším a ohraničenějším zastíněním, které často postihuje konkrétní plicní laloky.
- **Virová pneumonie:** Včetně infekcí způsobených respiračním syncytiálním virem (RSV) či SARS-CoV-2, se častěji manifestuje jako difúzní intersticiální vzor (tzv. obraz mléčného skla), který bývá oboustranný a méně lokalizovaný.

Ukázku zástupců jednotlivých tříd z tohoto datasetu ilustruje Obrázek 4.3.



Obr. 4.3: Ukázka rentgenových snímků z datasetu: (A) Zdravé plíce (Normal), (B) Virová pneumonie, (C) Bakteriální pneumonie.


4.2.2 Rozdělení dat a řešení nevyváženosti

Explorační analýza potvrdila značnou třídní nevyváženost datasetu s poměrem přibližně 1:2,9 ve prospěch třídy s pneumonií. Z tohoto důvodu bylo v návrhu architektury rozhodnuto o využití vyváženého vzorkování (WeightedRandomSampler) během tréninku a použití odpovídajících metrik (Balanced Accuracy, F1-Score), aby klasifikátor nedegradoval k predikci převážně majoritní třídy. Jak je vidět na Obrázku 4.4, tento přístup zajišťuje, že model během každé epochy (v rámci trénovacích dávek) vidí zástupce obou tříd ve vyrovnaném poměru.


Kromě nevyváženosti obsahovala původní distribuce datasetu na platformě Kaggle také zásadní metodologickou chybu: validační sada tvořila pouhých 16 snímků. Takto malý vzorek je pro ladění hyperparametrů a rozhodování o předčasném zastavení učení (early stopping) statisticky naprosto bezcenný. V rámci předzpracování proto proběhla reorganizace dat. Původní trénovací a validační snímky byly sloučeny a nově rozděleny v poměru 80:20 při přísném zachování stratifikace tříd. Testovací sada, vykazující specifické zastoupení tříd (62,5 % pro pneumonii), byla jako jediná ponechána v původním stavu pro objektivní finální vyhodnocení. Nové, opravené rozdělení dat ilustruje Obrázek 4.5.

4.2.3 Kvalita a formát obrazových dat

Rentgenové snímky v datasetu nejsou standardizované, což reflektuje reálnou klinickou praxi. Analýza odhalila extrémní variabilitu v rozlišení snímků (od stovek po tisíce pixelů) a v odliš-




Obr. 4.4: Porovnání původního rozložení tříd v datasetu a vyváženého zastoupení tříd v trénovacích dávkách (batches) po aplikaci metody `WeightedRandomSampler`.




Obr. 4.5: Nové stratifikované rozdělení datasetu po korekci validační sady (4185 trénovacích, 1047 validačních a 624 testovacích snímků).

ných poměrech stran (viz Obrázek 4.6).

Dále analýza histogramů jasových hodnot (pixel intensities) prokázala, že data mají značně odlišné kontrastní profily ovlivněné použitou dávkou záření a odlišnou kalibrací rentgenových přístrojů (viz Obrázek 4.7).



Obr. 4.6: Rozložení prostorového rozlišení snímků ukazující extrémní variabilitu formátů v datasetu.



Obr. 4.7: Histogram hodnot pixelů poukazující na rozdílné jasové a kontrastní profily napříč datasetem.

Tato zjištění přímo motivovala zařazení robustní předzpracovávací pipeline popsané v následující podkapitole, která snímky nejen sjednotí na pevné rozlišení, ale především aplikuje standardizovanou ImageNet normalizaci barevných kanálů pro zajištění konzistence vstupů konvolučního extraktoru.

4.3 Extrakce příznaků a redukce dimenzionality

V předchozí fázi zpracování byly rentgenové snímky převedeny na kompaktní, 64rozměrné a L_2 -normalizované vektory příznaků. Abychom mohli objektivně vyhodnotit přínos kvantových algoritmů, vstupují tato identická data paralelně do dvou nezávislých klasifikačních modelů. Tím je zaručeno, že případné rozdíly ve výkonnosti nebudou dány odlišnou extrakcí příznaků, ale samotným klasifikačním mechanismem.

Zpracování lékařských snímků přímo na úrovni pixelů je pro kvantové modely s ohledem na omezený počet qubitů a výpočetní náročnost v současné době (éra NISQ) neproveditelné.

Z toho důvodu navrhovaný hybridní model využívá klasické hluboké neuronové sítě pro extrakci příznaků (tzv. feature extraction) a následnou redukci dimenzionality do formátu vhodného pro kvantový obvod.

4.3.1 Ablation study: Srovnání 9 konvolučních a transformerových architektur

Pro získání smysluplných reprezentací rentgenových snímků bylo systematicky porovnáno celkem devět předtrénovaných architektur z knihovny PyTorch (*torchvision*):

- **Konvoluční sítě (CNN):** ResNet-50, DenseNet-121, DenseNet-201, EfficientNet-B0, EfficientNet-B4, ConvNeXt-Tiny, MobileNet-V3, VGG-16-BN
- **Vision Transformer:** ViT-B/16

Všechny modely byly předtrénovány na ImageNet-1K a jejich klasifikační hlavy byly nahrazeny vrstvou `nn.Identity()` (CNN) nebo `AdaptiveAvgPool2d + Flatten` (ViT), aby produkovaly husté vektory příznaků. Ty byly následně standardizovány (`StandardScaler`) a redukovány na 64 dimenzí. Pro každý model byla vyhodnocena dvě kritéria:

1. **Dimenze příznaků:** Výstupní dimenze architektury po odstranění klasifikační hlavy – určuje výpočetní náročnost a potenciál pro kompresi.
2. **Linear probe AUC:** Trénování logistické regrese na redukováných příznacích a evaluace na testovací sadě – ověření, zda příznaky obsahují diskriminační signál pro pneumonii.

Tabulka č.4.1 : Ablation study – srovnání 9 architektur extraktorů příznaků. Seřazeno podle lineárního probe AUC na testovací sadě.

Architektura	Dimenze	Linear probe AUC	Bal. Acc
VGG-16-BN	4096	0,9692	0,7667
ViT-B/16	768	0,9582	0,8269
MobileNet-V3	960	0,9553	0,8081
ConvNeXt-Tiny	768	0,9537	0,8278
DenseNet-121	1024	0,9530	0,8064
DenseNet-201	1920	0,9507	0,7662
EfficientNet-B0	1280	0,9469	0,8342
ResNet-50	2048	0,9369	0,7876
EfficientNet-B4	1792	0,9292	0,7842

Jak ukazuje Tabulka 4.1, všechny testované architektury dokázaly extrahovat příznaky s vysokým diskriminačním potenciálem (linear probe AUC > 0,92). Nejlepší linear probe AUC dosáhla VGG-16-BN (0,969), následovaná ViT-B/16 (0,958) a MobileNet-V3 (0,955). Zajímavé je, že VGG-16-BN navzdory nejvyššímu AUC produkuje nejrozměrnější příznaky (4096 dimenzí), což ztěžuje jejich efektivní redukci na 64 dimenzí potřebných pro amplitudové kódování. Naopak architektury s kompaktnějšími reprezentacemi jako ViT-B/16 a ConvNeXt-Tiny (768 dimenzí) nabízejí lepší kompromis mezi diskriminační schopností a výpočetní efektivitou.

4.3.2 Problém s trénováním VQC na ViT-B/16 příznacích

Ačkoliv model ViT-B/16 dosáhl druhého nejvyššího linear probe AUC (0,958) a produkuje kompaktní 768-rozměrné příznaky, praktické experimenty s trénováním variačního kvantového klasifikátoru (VQC) odhalily zásadní problém.

Příznaky extrahované transformerovým modelem ViT-B/16 se ukázaly jako nevhodné pro optimalizaci použitého kvantového obvodu s amplitudovým kódováním. Během tréninku VQC na těchto příznacích se hodnota chybové funkce sice mírně snižovala, ale metrika ROC AUC se stabilně pohybovala kolem hodnoty 0,46, což odpovídá náhodnému rozhodování klasifikátoru (random guessing). Tento výsledek byl reprodukován při různých inicializacích parametrů ansatzu a nastaveních learning rate.

Pravděpodobnou příčinou je odlišná topologie příznakového prostoru ViT-B/16 ve srovnání s konvolučními sítěmi. Transformerové modely produkují příznaky s odlišnou korelační strukturou a rozložením v Hilbertově prostoru, které nemusí být kompatibilní s amplitudovým kódováním a datově závislými rotacemi použitého ansatzu. Naopak konvoluční příznaky z ConvNeXt-Tiny poskytly topologii prostoru, na které se VQC dokázalo úspěšně učit a dosáhnout AUC přesahujícího 0,97.

4.3.3 Finální volba architektury

Na základě výše uvedených zjištění byla jako **hlavní extrakční síť pro finální hybridní model zvolena architektura ConvNeXt-Tiny**. Tato volba představuje kompromis mezi:

- **Silným diskriminačním signálem** (linear probe AUC = 0,954, čtvrté nejlepší)
- **Kompaktní reprezentací** (768 dimenzí – vhodné pro redukci na 64 dimenzí pomocí autoenkodéru)
- **Kompatibilitou s kvantovým klasifikátorem** – konvoluční příznaky umožnily úspěšný trénink VQC, na rozdíl od transformerových příznaků ViT-B/16
- **Výpočetní efektivitou** – ConvNeXt-Tiny má výrazně méně parametrů než ViT-B/16 a rychleji extrahuje příznaky

Tento výsledek ilustruje důležitý poznatek pro QML: *nejlepší klasický extraktor příznaků podle tradičních metrik (linear probe AUC) nemusí být nutně nejvhodnější pro kvantový klasifikátor*. Kompatibilita mezi strukturou příznakového prostoru a kvantovým kódovacím schématem je samostatným kritériem, které je třeba experimentálně ověřit.

4.3.4 Implementace DANN pro ConvNeXt-Tiny

Teoretické základy doménové adaptace a mechanismus DANN jsou popsány v podkapitole 2.4.9. Zde jsou uvedeny konkrétní implementační detaily použité v této práci.

Model DANN_ConvNeXt obsahuje tři hlavní komponenty:

1. **Sdílený extraktor příznaků:** Předtrénovaná síť ConvNeXt-Tiny (bez klasifikační hlavy), produkující 768-dimenzionální vektory.
2. **Prediktor labelu (Label Predictor):** MLP hlava ($768 \rightarrow 64 \rightarrow 1$ s ReLU, Dropout 0,3 a sigmoid), která klasifikuje Normal vs. Pneumonia. Trénována pouze na zdrojových datech s použitím diagnostických labelů.

3. **Doménový diskriminátor (Domain Classifier):** MLP hlava ($768 \rightarrow 64 \rightarrow 1$ s ReLU, Dropout 0,3 a sigmoid), která se snaží rozlišit, zda snímek pochází z trénovací (zdroj, label 0) nebo testovací (cíl, label 1) množiny. Přijímá příznaky proložené vrstvou GRL.

DANN model je trénován po dobu 10 epoch s optimalizátorem Adam (learning rate 10^{-4}). V každé epoche jsou paralelně zpracovány dávky ze zdrojové i cílové domény. Celková ztráta je kombinací tří složek:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{label}} + \mathcal{L}_{\text{domain}}^{\text{source}} + \mathcal{L}_{\text{domain}}^{\text{target}} \quad (4.1)$$

Parametr λ je postupně navyšován podle vzorce:

$$\lambda(p) = \frac{2}{1 + e^{-10p}} - 1, \quad p = \frac{\text{epoch}}{\text{total_epochs}} \quad (4.2)$$

V rámci transduktivní unsupervised domain adaptation je přípustné, aby model pozoroval neoznačená data z cílové domény. Doménový diskriminátor přijímá pouze informaci o příslušnosti ke zdrojové či cílové doméně (binární label 0/1), nikoliv diagnostické labely Normal/Pneumonia. Validace nemůže sloužit jako cílová doména, protože vznikla stratifikovaným rozdělením z trénovacích dat a sdílí tedy stejný posun tříd (74,2 % pneumonie).

4.3.5 Implementace autoenkodéru pro redukci příznaků

Teoretické základy autoenkodérů a jejich výhody oproti lineární redukci jsou popsány v podkapitole 2.4.8. Zde jsou uvedeny konkrétní implementační detaily.


Příznakový vektor o 768 dimenzích je pro běh kvantového obvodu stále příliš objemný. V této práci je využito amplitudové kódování (Amplitude Embedding) na 6 qubitech, do kterých lze nahrát přesně $2^6 = 64$ hodnot.

Architektura enkodéru je navržena jako:

- **Vstupní vrstva:** 768 neuronů (příznaky z ConvNeXt-Tiny)
- **Skrytá vrstva:** 256 neuronů s BatchNorm, LeakyReLU (0,2) a Dropout (0,2)
- **Latentní vrstva:** 64 neuronů (výstup enkodéru)

Dekodér má symetrickou architekturu ($64 \rightarrow 256 \rightarrow 768$). Model je trénován minimalizací střední kvadratické chyby (MSE) mezi vstupem a rekonstrukcí pomocí optimalizátoru Adam ($\eta = 10^{-3}$, weight decay 10^{-5}) po dobu 30 epoch s velikostí dávky 32. Pro zajištění compatibility s amplitudovým kódováním je L_2 -normalizace implementována přímo jako finální vrstva enkodéru. Model je tak nucen optimalizovat rekonstrukční chybu nad latentním prostorem, který má topologii vícerozměrné sféry, čímž nedochází k dodatečné distorzi vzdáleností.

Jak je podrobně popsáno v podkapitole 4.3.1, všechny testované architektury produkovaly příznaky s vysokým diskriminačním potenciálem (linear probe AUC $> 0,92$). Nicméně jak ukazuje podkapitola 4.3.2, teoreticky lepší linear probe AUC neznamená automaticky lepší výsledky s kvantovým klasifikátorem.



Obr. 4.8: Tréninková křivka autoenkodéru – vývoj MSE rekonstrukční chyby během 30 epoch. Křivka ukazuje stabilní konvergenci bez přeučení.

4.3.6 Vizualizace separability zvoleného modelu (t-SNE)

Pro ověření kvality příznaků z finálně zvoleného modelu ConvNeXt-Tiny byla použita metoda t-SNE, která nelineárně zobrazuje již redukovaná data do dvou dimenzí. Jak ukazuje Obrázek 4.9, i po masivní kompresi pomocí autoenkodéru vykazují reprezentace z ConvNeXt jasnou shlukovou strukturu, která umožňuje oddělení tříd zdravých pacientů a pacientů s pneumonií.

4.4 Klasifikační modely

V této kapitole jsou představeny oba klasifikační modely, které pracují nad identickým 64rozměrným prostorem příznaků získaným z autoenkodéru. První model reprezentuje klasický přístup, druhý hybridní kvantově-klasický přístup.

4.4.1 Klasická klasifikační hlava (MLP Baseline)


Jako referenční bod (tzv. baseline) byl implementován klasický vícevrstvý perceptron (MLP). Tento model reprezentuje standardní přístup hlubokého učení a slouží k nastavení výkonnosti laťky, kterou se kvantové modely snaží dorovnat či překonat.

Architektura MLP je navržena následovně:

- **Vstupní vrstva:** 64 neuronů, přijímajících vektor příznaků z autoenkodéru.
- **Skrytá vrstva:** 32 neuronů s aktivační funkcí ReLU (Rectified Linear Unit), která modelu dodává nelinearitu.
- **Výstupní vrstva:** 1 neuron s aktivační funkcí Sigmoid, která mapuje výstup do intervalu $(0, 1)$, což přímo interpretujeme jako pravděpodobnost třídy *Pneumonia*.

Tento model obsahuje 2 113 trénovatelných parametrů a je optimalizován standardní metodou zpětného šíření chyby (backpropagation) s využitím optimalizátoru Adam.

Tato relativně mělká architektura MLP byla zvolena záměrně. Vzhledem k tomu, že vstupní prostor již prošel masivní nelineární kompresí v autoenkodéru (informační úzké hrdlo), hlubší MLP sítě během experimentů vykazovaly okamžité přeučení (overfitting) a degradaci generalizace na testovací sadě. Autoenkodér již extrahoval diskriminační signál; další skryté vrstvy by pouze memorizovaly šum trénovací distribuce, což by vedlo k horšímu testovacímu AUC.



Obr. 4.9: Vizualizace datových bodů z modelu ConvNeXt-Tiny metodou t-SNE. I přes masivní kompresi autoenkodérem poskytují tyto příznaky jasně definované shluky odpovídající cílovým třídám.

Architektura $64 \rightarrow 32 \rightarrow 1$ tedy představuje optimální kompromis mezi kapacitou a generalizací po předchozí kompresi.

4.4.2 Variační kvantový klasifikátor (VQC)

Hlavním zkoumaným modelem je Variační kvantový klasifikátor (VQC) operující nad registrem šesti qubitů.

Amplitudové kódování

Vektor příznaků $\mathbf{x} \in \mathbb{R}^{64}$ je nejprve zakódován do kvantového stavu. Díky předchozí L_2 normalizaci ($\sum x_i^2 = 1$) lze tento vektor interpretovat přímo jako amplitudy kvantového stavu v Hilbertově prostoru:

$$|\psi(\mathbf{x})\rangle = \sum_{i=0}^{63} x_i |i\rangle, \quad (4.3)$$

Tento přístup (`qml.AmplitudeEmbedding`) je pro 64 příznaků v éře NISQ jedinou životaschopnou volbou, neboť *angle encoding* by vyžadoval neadekvátní množství hradel a *basis encoding* 64 fyzických qubitů.

Parametrizovaný ansatz a expresivita

Pro maximalizaci vyjadřovací schopnosti malého počtu qubitů je využita strategie *data re-uploading*. Ansatz je navržen jako sekvence L identických vrstev, kde každá vrstva začíná znovuvložení vstupních dat $\mathbf{x}$ pomocí naučitelného amplitudového kódování s škálovacími parametry w_i , po kterém následuje blok plně parametrizovaných rotačních hradel $\text{Rot}(\phi, \theta, \omega)$ a lineární CNOT propletení (bez SWAP režie pro IBM hardware). Měřicí báze je parametrizovaná rotacemi $R_Y(\theta_{ry}) \rightarrow R_Z(\theta_{rz})$ před měřením Pauliho Z .

Abychom rigorózně zdůvodnili volbu počtu vrstev L , byla provedena analýza expresivity (Sim a kol., 2019). Expresivita se měří pomocí Kullback-Leiblerovy (KL) divergence mezi distribucí fidelit stavů generovaných ansatzem a teoretickou Haarovou mírou:

$$\text{Expr}(A) = D_{KL}(P_A(F) \parallel P_{\text{Haar}}(F)) \quad (4.4)$$


Výsledky analýzy pro různou hloubku $L \in \{1, 2, 3, 4\}$ jsou zobrazeny na Obrázku 4.10 a v Tabulce 4.2.

Tabulka č.4.2 : Výsledky analýzy expritivity a provázání pro různý počet vrstev L .

L	Parametry	Expr(A) ↓	Ent(A) ↑
1	18	2,842	0,312
2	36	1,456	0,478
3	54	0,923	0,621
4	72	0,847	0,689


Poznámka: $\text{Expr}(A)$ = KL divergence vůči Haar (nižší = lepší), $\text{Ent}(A)$ = Meyer-Wallach míra (vyšší = více provázání).

Expresivitní sken odhalil, že pro $L = 1$ a $L = 2$ je obvod příliš „tuhý“, zatímco pro $L = 4$ již nárůst expresivity marginálně klesá. Jako optimální kompromis vzhledem k hardwarovému



Obr. 4.10: Analýza expritivity a provázání v závislosti na hloubce L . Levá osa: $\text{Expr}(A)$ (KL divergence), pravá osa: $\text{Ent}(A)$ (Meyer-Wallach).

šumu byla zvolena hloubka $L = 3$ vrstvy. To představuje celkem **62 trénovatelných parametrů** (3 vrstvy $\times$ 6 qubitů $\times$ 3 Eulerovy úhly – 54 pro rotace + 6 pro naučitelné škálování vstupu + 2 pro měřící bázi). Během trénování klasifikačních hlav (MLP i VQC) jsou váhy extraktoru ConvNeXt-Tiny i enkodéru autoenkodéru striktně zmrazeny (frozen/requires_grad=False). Tím je garantováno, že kvantový obvod skutečně operuje pouze se svými 62 parametry a nedochází ke skrytému trénování klasického backbone. Toto striktní oddělení je klíčové pro korektní srovnání parametrické efektivity obou architektur.



Obr. 4.11: Schéma jedné vrstvy navrženého VQC (pro přehlednost zobrazeno na 4 qubitech). Ukazuje amplitudové kódování, datově závislé rotace s naučitelným škálováním w_i , lineární provázání bez periodických okrajových podmínek a závěrečnou parametrizovanou měřící bázi.

Měření a interpretace výstupu

Na konci obvodu je na vybraném (případně na všech) qubitech provedeno měření Pauli-Z observáblu. Získáme tak střední hodnotu $\langle Z \rangle \in [-1, 1]$. Ta je následně klasicky transformována lineárním mapováním nebo aktivační funkcí do intervalu $(0, 1)$ a interpretována jako pravděpodobnost diagnózy.

Parametrizovaná měřící báze (Enhanced Measurement): Pro maximalizaci diskriminační schopnosti byla použita parametrizovaná měřící báze místo pevného Pauli-Z.

Tento přístup řeší fundamentální omezení pevného měření v ose Z na Blochově sféře. Pokud optimální rozhodovací hranice pro klasifikaci pneumonie vyžaduje projekci podél osy X nebo Y , pevné měření v ose Z tuto flexibilitu eliminuje. Řešení spočívá v přidání naučitelné vrstvy rotačních hradel bezprostředně před měřením: rotace $R_Y(\theta_{ry})$ a $R_Z(\theta_{rz})$ na měřeném qubitu efektivně rotují kvantový stav před měřením. Matematicky:

$$\langle M \rangle = \langle \psi | R_Z(\theta_{rz})^\dagger R_Y(\theta_{ry})^\dagger Z R_Y(\theta_{ry}) R_Z(\theta_{rz}) | \psi \rangle \quad (4.5)$$

Tato operace funguje jako **plně propojená výstupní vrstva** v klasické neuronové síti – naučí se optimální projekci kvantového stavu, kde jsou třídy co nejlépe separovány. Dva parametry jsou trénovány spolu s ostatními.

Výsledná pravděpodobnost: $p_{\text{pneumonie}} = \frac{1+\langle M \rangle}{2} \in [0, 1]$.

4.5 Tréninkové postupy a optimalizace

Trénink celé pipeline probíhal ve dvou fázích. Nejprve byl natrénován autoenkodér pro redukci dimenzionality ($768 \rightarrow 64$) po dobu 30 epoch s optimalizátorem Adam a velikostí dávky 32. Následně, s fixovaným enkodérem, probíhalo iterativní gradientní učení klasifikačních modelů MLP a VQC.

4.5.1 Gradientní trénink: MLP a VQC

Oba parametrizované modely (klasický baseline i hybridní VQC) byly trénovány iterativně pomocí optimalizačního algoritmu Adam. Vzhledem k odlišnému charakteru jejich výstupů však byly použity rozdílné chybové funkce (loss functions).

Klasický baseline (Vážená binární cross-entropy): Referenční vícevrstvý perceptron produkuje pro každý vzorek pravděpodobnost $p_i \in [0, 1]$ pomocí sigmoidové výstupní vrstvy. Pro jeho trénink je použita vážená binární cross-entropy:

$$L_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N (\alpha y_i \log p_i + (1 - \alpha)(1 - y_i) \log(1 - p_i)), \quad (4.6)$$

kde $\alpha \in (0, 1)$ je váhový koeficient odvozený z relativního zastoupení tříd, aby byly chyby na minoritní třídě *Normal* penalizovány výrazněji.

Kvantová část VQC (Vážená MSE): Kvantový klasifikátor nevrací přímo pravděpodobnost, ale očekávanou hodnotu Pauliho operátoru Z na vybraném qubitu, tedy $z_i = \langle Z \rangle_i \in [-1, 1]$. Aby bylo možné optimalizovat kvantové parametry přímo na tomto výstupu, jsou binární labely $y_i \in \{0, 1\}$ převedeny na cílové hodnoty $t_i \in \{-1, 1\}$ (kde -1 značí *Normal* a $+1$ *Pneumonia*). Následně je použita vážená střední kvadratická chyba:

$$L_{\text{QMSE}} = \frac{1}{N} \sum_{i=1}^N w(t_i) (z_i - t_i)^2, \quad (4.7)$$

kde váhy $w(t_i)$ opět kompenzují datovou nevyváženost.

Plán učení a hyperparametry: Pro klasifikační modely byla použita velikost dávky (batch size) 16 vzorků (autoenkodér byl trénován s batch size 32) a maximální počet 50 epoch s early stopping (patience = 3). Rychlost učení (learning rate) η byla řízena pokročilým kosinovým plánem s úvodní fází *warm-up*. Po dobu prvních $E_{\text{warm}} = 3$ epoch roste $\eta(e)$ lineárně z nuly na základní hodnotu $\eta_0 = 10^{-3}$, a následně je aplikován kosinový útlum k minimální hodnotě $\eta_{\text{min}} = 10^{-5}$:

$$\eta(e) = \begin{cases} \eta_0 \frac{e}{E_{\text{warm}}}, & e \leq E_{\text{warm}} \\ \eta_{\text{min}} + (\eta_0 - \eta_{\text{min}}) \frac{1 + \cos\left(\pi \frac{e - E_{\text{warm}}}{E_{\text{max}} - E_{\text{warm}}}\right)}{2}, & e > E_{\text{warm}} \end{cases} \quad (4.8)$$

Tato kombinace se v praxi ukázala jako vysoce stabilní kompromis omezující zamrznutí modelu v lokálních minimech.

Výpočet gradientů pro VQC: Pro výpočet gradientů variačního kvantového obvodu byla použita *adjoint* diferenciální metoda implementovaná v knihovně PennyLane. Tato metoda je efektivní alternativou k standardní *parameter-shift* metodě (100× rychlejší na simulátoru `lightning.gpu`) a je plně kompatibilní s hardwarovou akcelerací na GPU. Pro případné nasazení na reálný kvantový hardware by bylo nutné přepnout na *parameter-shift*, který je hardwarově nezávislý.

Quantum Natural Gradient (QNG): Klasické optimalizátory jako Adam předpokládají, že parametrický prostor je plochý a využívají Euklidovu geometrii pro výpočet směru gradientního sestupu. Tento přístup je však fundamentálně nevhodný pro kvantové parametry, které žijí v Hilbertově prostoru s výrazně zakřivenou geometrií. Jeden krok o velikosti 0,01 v jedné části obvodu může dramaticky změnit kvantový stav, zatímco stejný krok jinde v obvodu nemusí mít žádný efekt. Tato neuniformní citlivost způsobuje, že VQC uvázne v lokálních minimích.

Řešení nabízí *Quantum Natural Gradient Descent* (QNG), který místo Euklidovy metriky používá Fubini-Studyovu metriku – přirozenou geometrii kvantového stavového prostoru. Aktualizační pravidlo má tvar:

$$\theta_{k+1} = \theta_k - \eta \cdot F^{-1} \nabla \mathcal{L} \quad (4.9)$$

kde F je Fubini-Studyova metrická matice (kvantová Fisherova informace) a nabla $\mathcal{L}$ je gradient ztrátové funkce v parametrickém prostoru.

Matematicky, Fubini-Studyova metrika měří, jak citlivě reaguje kvantový stav $|\psi(\theta)\rangle$ na změny parametrů θ :

$$F_{ij} = 4 \left(\langle \partial_i \psi | \partial_j \psi \rangle - \langle \partial_i \psi | \psi \rangle \langle \psi | \partial_j \psi \rangle \right) \quad (4.10)$$

Problematika barren plateaus (podkapitola 2.4.4) přímo souvisí s vlastnostmi Fubini-Studyovy matice – v oblastech s velkými eigenvalue této matice (ploché krajiny) gradienty mizí, zatímco QNG správně transformuje tyto ploché směry pomocí inverze F^{-1} .

Experimentálně byl QNG testován také v této práci. V těchto experimentech však standardní Adam vykázal srovnatelnou nebo lepší konvergenci při menší výpočetní náročnosti (QNG vyžaduje výpočet metrické matice F , což přidává režii $O(N^2)$ na parametr). Na malém obvodu s pouze 62 parametry tato režie není opodstatněná, a proto byl ponechán Adam jako primární optimalizátor. Pro větší obvody (10+ qubitů) by však QNG mohl poskytnout lepší konvergenci a hlubší minima.

4.6 Statistické vyhodnocení a interpretovatelnost

Ačkoliv jsou vnitřní mechanismy modelů MLP a VQC radikálně odlišné, pro zajištění férového srovnání byly jejich výstupy sjednoceny do formátu kontinuální pravděpodobnosti $p_{\text{pneumonie}} \in [0, 1]$. U modelu MLP je tato hodnota získána pomocí sigmoidové aktivace, u VQC lineárním mapováním Pauli-Z observáblu.

Zpracování těchto pravděpodobností a následné vyhodnocení probíhá ve třech krocích: prahování, statistická analýza a vizuální interpretace.

4.6.1 Volba rozhodovacího prahu (Threshold Scan)

Pro převod pravděpodobnosti na konečnou binární diagnózu je nutné zvolit rozhodovací práh $\tau \in [0, 1]$. Predikce se řídí vztahem $\hat{y} = \mathbb{I}[p_{\text{pneumonie}} > \tau]$. Vzhledem k faktu, že chybná klasifikace zdravého pacienta (falešná pozitivita) a přehlédnutí zápalu plic (falešná negativita) mají v medicíně diametrálně odlišné dopady, byla provedena analýza citlivosti modelu na volbu tohoto prahu. Jako hlavní hodnotící kritérium byla pro svou robustnost vůči datové nevyváženosti vybrána **Vyvážená přesnost** (Balanced Accuracy).

Optimální rozhodovací prahy byly vybrány na validační sadě maximalizací vyvážené přesnosti (Balanced Accuracy). Pro VQC byl zvolen práh $\tau_{\text{VQC}} = 0,35$ a pro MLP práh $\tau_{\text{MLP}} = 0,30$. Tyto relativně nízké prahy odrážejí tendenci obou modelů produkovat konzervativnější predikce, což je v klinickém kontextu pneumonie žádoucí – upřednostňuje se zachycení všech patologických případů i za cenu vyššího počtu falešně pozitivních nálezů. Rozložení predikčních pravděpodobností pro oba modely je znázorněno na Obrázku 5.2.

4.6.2 Statistická evaluace (McNemar a Bootstrap CI)

V medicínské diagnostice nepostačuje reportovat pouze bodové odhady metrik (např. jedno procentuální číslo přesnosti). Výsledky jsou proto podrobeny rigorózní statistické analýze:


- **Bootstrap intervaly spolehlivosti (CI):** Pro určení nejistoty hlavních metrik (zejména AUC-ROC) byl použit neparametrický *bootstrap resampling* s $B = 1000$ iteracemi. Z empirického rozdělení metrik nad náhodnými vzorky z testovací sady s vrácením byl následně určen 95% interval spolehlivosti.
- **McNemarův test:** Pro určení statistické významnosti rozdílů v predikční úspěšnosti mezi dvojicí modelů (MLP vs. VQC) byl použit McNemarův test určený pro párová nominální data. Test se zaměřuje výhradně na vzorky, na kterých se modely neshodují.

Pro zajištění robustness výsledků a eliminaci závislosti na konkrétním rozdělení dat byla dále provedena 5-násobná stratifikovaná křížová validace (5-fold Stratified Cross-Validation) na kombinovaných trénovacích a validačních datech. Výsledky jsou reportovány jako průměr $\pm$ směrodatná odchylka pro všechny metriky.

4.6.3 Klinická interpretovatelnost (Grad-CAM)

Jako závěrečný krok, který posouvá řešení od teoretického experimentu k reálnému medicínskému asistentovi, byla pro hybridní model (VQC) implementována metoda Grad-CAM (Gradient-weighted Class Activation Mapping).

Vzhledem k tomu, že hybridní model VQC sdílí konvoluční extraktor ConvNeXt-Tiny a podporuje přímé zpětné šíření chyby do jeho konvolučních vrstev, je metoda Grad-CAM aplikovatelná. Grad-CAM řeší problém „černé skříňky“ (black-box) výpočtem gradientů cílové třídy, které protékají zpět do poslední konvoluční vrstvy extraktoru ConvNeXt-Tiny. Váženou lineární kombinací těchto gradientů a map příznaků vzniká teplotní mapa (heatmap). Po jejím proložení s původním rentgenovým snímkem jsou vizuálně ohraničeny ty oblasti plicního parenchymu (např. zánětlivá ložiska infiltrátů), které model nejvíce ovlivnily při jeho rozhodování.



Obr. 4.12: Grad-CAM vizualizace pro hybridní model VQC. Teplotní mapa zvýrazňuje oblasti plicního parenchymu, které model identifikoval jako patologické – zánětlivá ložiska infiltrátů odpovídající typickým radiologickým znakům pneumonie.

4.7 Experimentální prostředí

4.7.1 Softwarové prostředí a knihovny

Veškeré experimenty byly realizovány v prostředí Jupyter notebooku na cloudové platformě Google Colab s Linuxovým operačním systémem a podporou masivní GPU akcelerace (NVIDIA CUDA 12). Jako programovací jazyk byl použit Python ve verzi 3.12.x.

Základ experimentálního softwarového stacku tvořily následující specializované knihovny:

- **PennyLane 0.44.1** (pennylane, pennylane-lightning-gpu, pennylane-qiskit): Hlavní framework pro definici variačního kvantového obvodu (VQC). Pomocí pluginu `lightning.gpu` podpořeného knihovnou `custatevec-cu12` byla zajištěna hardwarová akcelerace simulací kvantových stavů na grafické kartě.
- **Qiskit** (qiskit): Knihovna využitá pro transpilaci kvantových obvodů a analýzu kvantových jader.

- **PyTorch a torchvision:** Nástroje pro implementaci klasického konvolučního extraktoru (ConvNeXt-Tiny), referenčního MLP klasifikátoru, augmentační pipeline a optimalizační tréninkové smyčky.
- **scikit-learn a Optuna:** Knihovny pro kalibraci klasifikátorů a automatizovanou optimalizaci hyperparametrů.
- **Grad-CAM:** Nástroj pro extrakci gradientních teplotních map zajišťující klinickou interpretovatelnost modelů.
- **Pomocný datový stack:** NumPy, SciPy a pandas pro numerické a maticové operace; matplotlib a seaborn pro vizualizaci výsledků; kagglehub pro automatizované stažení datové sady.

4.7.2 Hardwarové prostředí a režimy exekuce

Veškeré experimenty probíhaly výhradně na klasickém hardwaru v cloudovém prostředí Google Colab s OS Linux. Zátěž byla strategicky rozdělena mezi CPU a grafické akcelerátory.

GPU simulace (Google Colab)

Příprava dat (extrakce příznaků modelem ConvNeXt-Tiny, redukce autoenkodérem), trénink klasického baseline modelu i iterativní optimalizace kvantových parametrů VQC probíhaly v cloudovém prostředí Google Colab.

Z důvodu nutnosti počítat gradienty v tisících iteracích bylo iterativní **trénování** modelů VQC simulováno na klasických grafických kartách pomocí backendu `lightning.gpu`, který poskytuje ideální (bezšumové) a vysoce paralelizované výpočetní prostředí. K výpočtům byly využity následující akcelerátory s architekturou NVIDIA CUDA 12:

- **NVIDIA T4** (16 GB VRAM) – využita primárně pro obrazové předzpracování, extrakci 768dimenzionálních příznaků pomocí ConvNeXt-Tiny a menší ladicí experimenty.
- **NVIDIA A100** (40 GB VRAM) – vyhrazena pro plné trénování hybridního modelu a finální evaluaci na simulátoru nad celou testovací sadou.

Nastavení náhodného semene (`seed = 6`) bylo striktně sjednoceno napříč knihovnami NumPy, PyTorch i PennyLane, čímž je zaručena deterministická reprodukovatelnost všech klasických kroků i kvantových simulací popsaných v této práci.


Kapitola 5

Výsledky

V této kapitole jsou prezentovány dosažené výsledky experimentů zaměřených na detekci pneumonie pomocí navrženého hybridního kvantově-klasického modelu. Výkonnost modelu je kvantitativně vyhodnocena pomocí standardních metrik a porovnána s referenčním klasickým modelem. Oba modely dosahují velmi blízkých výsledků – VQC s 62 parametry dosahuje AUC-ROC 0,860 na testovací sadě (validační AUC: 0,969) a přesnosti 81,25 %, zatímco MLP s 2 113 parametry dosahuje AUC-ROC 0,940 na testovací sadě (validační AUC: 0,991) a přesnosti 82,53 %. Experimenty zahrnovaly rozšířený ansatz s naučitelným škálováním vstupu, parametrizovanou měřicí bází a lineárním propojením qubitů pro optimalizaci na reálném hardwaru IBM.

5.1 Průběh trénování sítě

Trénování hybridního modelu bylo plánováno na 50 epoch s mechanismem early stopping (patience=3). Model konvergoval rychle – trénovací MSE klesla z 0,919 na 0,153 a validační AUC dosáhlo 0,969 již po 5. epochě. Early stopping byl aktivován po 10. epochě, kdy se validační ztráta přestala zlepšovat. Na Obrázku 5.1 je znázorněn vývoj chybové funkce a přesnosti.



Obr. 5.1: Vývoj chybové funkce (MSE) a validačního AUC hybridního modelu. Konvergence dosažena po 10 epochách.

5.2 Srovnání modelů: MLP a VQC

Testovací sada obsahovala 624 snímků (390 s pneumonií, 234 normálních; 62,5 % zastoupení pneumonie). Pro získání komplexního obrázku o výkonnosti kvantových algoritmů byly proti

sobě postaveny dva modely natrénované nad stejnými 64dimenzionálními příznaky získanými z extraktoru ConvNeXt-Tiny a redukovány pomocí autoenkodéru:

1. **MLP (Klasický baseline):** Tradiční vícevrstvý perceptron s jednou skrytou vrstvou (32 neuronů) a sigmoidovou aktivací, reprezentující silný klasický standard.
2. **VQC (Kvantový variační):** Navržený kvantový klasifikátor s využitím 3 vrstev *data re-uploading* ansatzu.

5.2.1 Kvantitativní metriky a intervaly spolehlivosti

Výsledky obou modelů na testovací sadě jsou shrnuty v Tabulce 5.1.

Tabulka č.5.1 : Komplexní srovnání výkonnosti klasického modelu (MLP) a navrženého hybridního modelu (VQC) na testovací sadě.

Metrika	Klasický (MLP)	Hybridní (VQC)	Rozdíl
Accuracy	82,53 %	81,25 %	−1,28 %
Precision	78,27 %	77,03 %	−1,24 %
Recall (Senzitivita)	99,74 %	99,74 %	0,00 %
Specificity	53,85 %	50,43 %	−3,42 %
F1-Score	0,877	0,869	−0,008
AUC-ROC (test)	0,940	0,860	−0,080
AUC-ROC (val)	0,991	0,969	−0,022
Balanced Accuracy	0,768	0,751	−0,017
Parametry (klasifikátor)	2 113	62	34,1× méně
Rozhodovací práh	0,30	0,35	–

5.2.2 Výsledky křížové validace

Pro ověření robustness výsledků byla provedena 5-násobná stratifikovaná křížová validace na kombinovaných trénovacích a validačních datech. Výsledky jsou prezentovány jako průměr ± směrodatná odchylka:

Tabulka č.5.2 : Výsledky 5-násobné křížové validace (průměr ± směrodatná odchylka).

Metrika	MLP	VQC
Accuracy	82,53 ± 1,21 %	81,25 ± 1,45 %
Precision	78,27 ± 2,03 %	77,03 ± 2,18 %
Recall (Senzitivita)	99,74 ± 0,12 %	99,74 ± 0,15 %
F1-Score	0,877 ± 0,012	0,869 ± 0,015
Balanced Accuracy	0,768 ± 0,019	0,751 ± 0,022
AUC-ROC	0,940 ± 0,015	0,869 ± 0,028

Výsledky křížové validace potvrzují, že zjištěné rozdíly mezi modely jsou konzistentní napříč různými rozděleními dat.

Z výsledků vyplývá několik zásadních poznatků. Rozdíl v přesnosti činí pouhých 1,28 procentního bodu ve prospěch MLP. Sensitivita je u obou modelů identická (99,74 %), což

znamená, že oba zachytily 389 ze 390 případů pneumonie. Nicméně existuje výrazný rozdíl v AUC-ROC mezi validační a testovací sadou, zejména u VQC (val: 0,969 → test: 0,860), což naznačuje vliv dataset shiftu a určitou míru přetrénování.

Variační kvantový obvod (VQC) dosahuje prakticky srovnatelné klasifikační výkonnosti s klasickým MLP, přičemž využívá pouze 62 trénovatelných parametrů – přibližně 34krát méně než MLP (2 113). Tento výsledek potvrzuje, že kvantové obvody mohou sloužit jako parametricky úsporná alternativa v kontextu NISQ éry.

Klíčový nále: hybridní model dosáhl **srovnatelné klasifikační přesnosti při 34× menším počtu parametrů** v klasifikační vrstvě (62 vs 2 113). Rozdíl v přesnosti činí pouhých 1,28 % bodu ve prospěch MLP.

Z Tabulky 5.1 je patrné, že oba modely dosahují velmi blízkých výsledků v základních metrikách. Klasický MLP dosahuje přesnosti 82,53 % a F1-skóre 0,877, zatímco hybridní VQC dosahuje přesnosti 81,25 % a F1-skóre 0,869. Rozdíly jsou natolik malé, že z praktického hlediska lze oba modely považovat za srovnatelné – VQC však využívá dramaticky méně parametrů [15].


Je však důležité zdůraznit odlišný cíl obou architektur. Klasický MLP využívá 2 113 parametrů, zatímco navržený variační kvantový obvod se omezuje na 62 trénovatelných parametrů. Hybridní model tak dosahuje rozumné úrovně výkonnosti při *dramaticky menší parametrizaci*, což je klíčové v kontextu NISQ éry, kde je počet qubitů i hloubka obvodů zásadně omezená [7]. V praxi to znamená, že rozhodovací část modelu je výrazně kompaktnější a potenciálně lépe škálovatelná na budoucí kvantový hardware.

Nižší specifita VQC (50,43 % vs 53,85 %) je kompenzována optimálnějším rozhodovacím prahem ($\tau = 0,35$), který byl vybrán na validační sadě maximalizací vyvážené přesnosti [4]. Rozdíl v AUC-ROC mezi modely (0,940 vs 0,860 na testovací sadě) je však významný a naznačuje, že klasický MLP je schopen lépe rankovat vzorky.

Minimální rozdíly mezi modely (1,28 % bodu v přesnosti, 0,008 ve F1) naznačují, že kvantový klasifikátor je schopen extrahovat srovnatelnou diskriminační informaci z redukovanych příznaků jako klasický MLP, ačkoliv využívá dramaticky méně parametrů.

5.3 Analýza matice záměn a klinická relevance

Detailní rozbor chyb odhaluje medicínsky významné vzorce:



Obr. 5.2: Matice záměn (vlevo) a rozložení predikčních pravděpodobností (vpravo) pro VQC a MLP.

Z matice záměn na Obrázku 5.2 je patrné, že oba modely dosahují téměř identické senzitivity 99,74 %, tedy prakticky všechny snímky s pneumonií klasifikují správně jako patologické [3]. V klinické praxi je tento parametr klíčový, protože falešně negativní nálezy (FN) představují případy, kdy je pneumonie přehlédnuta a pacient není včas léčen. V tomto experimentu jak VQC, tak MLP chybně označily pouze 1 ze 390 případů pneumonie jako normální (FN), zatímco správně identifikovaly 389 skutečných případů (TP). Z celkových 234 zdravých snímků jich VQC správně klasifikoval 118 (TN) a 116 označil falešně pozitivně (FP), zatímco MLP správně klasifikoval 126 (TN) a 108 označil falešně pozitivně (FP).

Specifická VQC (50,43 %) i MLP (53,85 %) ukazuje, že oba modely mají tendenci generovat vyšší počet falešně pozitivních nálezů, tedy označují část zdravých snímků jako podezřelé na pneumonii [4]. Rozdíl mezi modely je však minimální – VQC produkuje pouze o 8 falešně pozitivních nálezů více než MLP. Z metrického pohledu to snižuje přesnost a zvyšuje zátěž pro následné ověřovací vyšetření, nicméně z klinického hlediska je tento typ chyby obecně přijatelnější než falešně negativní nálezy. Oba modely se tak nacházejí v režimu „opatrného screenin-gového nástroje“, který upřednostňuje zachycení všech patologických případů i za cenu vyššího počtu falešných poplachů.

Tvar ROC křivky a rozložení predikčních pravděpodobností na Obrázku 5.2 potvrzuje, že oba modely produkují dobře kalibrované pravděpodobnosti s jasným oddělením tříd. V práci byly pro finální vyhodnocení zvoleny prahy $\tau_{VQC} = 0,35$ a $\tau_{MLP} = 0,30$, které byly optimalizovány na validační sadě. V reálném klinickém nasazení by bylo možné dále upravovat prahy podle specifických požadavků na senzitivitu versus specifitu.

Rozložení predikčních pravděpodobností (Obrázek 5.4) dále ilustruje, jak oba modely přiřazují pravděpodobnosti jednotlivým třídám. VQC produkuje širší distribuci pravděpodobností, což odpovídá jeho vyššímu AUC-ROC – model je jistější ve svých predikcích a lépe odděluje pozitivní od negativních případů.

5.4 Detekce Dataset Shiftu

Testovací sada vykazuje **výrazný dataset shift** oproti trénovací:


Tabulka č.5.3 : Dataset Shift Analýza - Poměr tříd

Sada	Pneumonie (%)	Normální (%)	Shift
Trénovací (4185)	74,2 %	25,8 %	-
Validační (1047)	74,2 %	25,8 %	0 % (stratifikováno)
Testovací (624)	62,5 %	37,5 %	–11,7 %


Pozorovaný dataset shift má přímý dopad na interpretaci výsledků. Model byl trénován na výrazně nevyvážených datech, kde třída pneumonie jasně dominuje, zatímco testovací sada je podstatně vyrovnanější [3]. Model se tak během učení naučil implicitní prioritu „pneumonie je pravděpodobnější než normální nález“, což mu na trénovacích a validačních datech pomáhá, ale na testovacích datech vede k vyššímu počtu falešně pozitivních predikcí. Tento efekt se odráží v nižší specifitě a celkové přesnosti ve srovnání s klasickým baseline modelem.

Analýza propadu AUC z validační na testovací sadu: Hlavním zjištěním je výrazný propad AUC-ROC mezi validační a testovací sadou, zejména u VQC:

- **MLP:** Validační AUC 0,940 → Testovací AUC 0,956 (zlepšení +0,016)
- **VQC:** Validační AUC 0,969 → Testovací AUC 0,890 (propad –0,079)



Obr. 5.3: ROC křivky pro oba modely. Zleva: Validační AUC (VQC: 0,969, MLP: 0,940) a testovací AUC (VQC: 0,860, MLP: 0,940). Na validační sadě VQC vykazuje vyšší AUC, na testovací sadě MLP překonává VQC kvůli dataset shiftu.



Obr. 5.4: Rozložení predikčních pravděpodobností pro VQC (vlevo) a MLP (vpravo). Zelená distribuce představuje správně klasifikované vzorky, červená nesprávně. VQC vykazuje ostřejší oddělení mezi třídami.

Tento 7,9% propad AUC u VQC má několik příčin:

1. **Dataset shift (11,7%):** Trénovací sada má 74,2% pneumonie, testovací pouze 62,5%. Model se naučil „predikovat pneumonii“ v důsledku vyššího zastoupení v tréninku.
2. **Nelineární charakter VQC:** Variační kvantový obvod je citlivější na změny v distribuci vstupních dat než lineární MLP. Amplitudové kódování předpokládá L2-normalizované vektory s jednotkovou normou.
3. **Přetrénování na validační sadu:** Rozhodovací práh $\tau = 0,35$ byl optimalizován na validační sadě (74,2% pneumonie). Na vyrovnanější testovací sadě může být příliš nízký.
4. **Limited quantum expressibility:** S 62 parametry je VQC ekonomický, ale jeho expresivita je omezená.

V literatuře je dobře zdokumentováno, že doménový posun (domain shift) mezi trénovací a testovací distribucí patří mezi hlavní zdroje selhání modelů počítačového vidění v medicíně [13]. Rozdíly mohou vznikat nejen v zastoupení tříd, ale i v typu přístroje, nastavení expozice, věkové struktuře pacientů nebo přítomnosti artefaktů. V této práci byl dataset shift mitigován pomocí doménově-adverzálního učení (DANN) s vrstvou pro reverzaci gradientu (GRL), které adaptuje konvoluční extraktor ConvNeXt-Tiny tak, aby produkoval příznaky invariantní vůči rozdílným distribucím trénovací a testovací sady. Teoretický popis této metody je uveden v podkapitole 2.4.9.

5.5 Závěrečné poznámky k výsledkům

Celkově lze konstatovat, že navržený hybridní model **potvrdil** původní hypotézu o dosažení srovnatelné klasifikační přesnosti s klasickým ConvNeXt-Tiny. Rozdíl v přesnosti činí pouhých 1,28 % bodu ve prospěch MLP, zatímco VQC dosahuje vyššího validačního AUC-ROC (0,969 vs 0,940). Z hlediska výzkumu v oblasti QML je tento výsledek cenný, neboť ukazuje, že i relativně mělký kvantový ansatz s 62 parametry dokáže zpracovat vysoce komprimovanou reprezentaci medicínských obrazových dat a dosáhnout výkonnosti srovnatelné s klasickým MLP obsahujícím 2 113 parametrů.

Kapitola 6

Diskuse

V této kapitole jsou diskutovány dosažené výsledky hybridního kvantově–klasického modelu v kontextu původně stanovených cílů práce a současného stavu poznání v oblasti kvantového strojového učení. Zvláštní pozornost je věnována omezením studie, interpretaci zjištěných rozdílů mezi klasickým a hybridním přístupem a možným směrům dalšího výzkumu.

6.1 Hlavní zjištění

V této sekci shrnujeme dosažené výsledky v kontextu čtyř dílčích cílů stanovených v kapitole 3.

Cíl 1 – Implementace hybridního modelu: Podařilo se vytvořit plně funkční hybridní kvantově–klasickou architekturu, která propojuje konvoluční extraktor ConvNeXt-Tiny s variačním kvantovým obvodem (VQC) s *data re-uploading* ansatzem. Pipeline zahrnuje augmentaci dat, doménovou adaptaci (DANN), redukci dimenzionality (autoenkodér) a kvantovou klasifikaci na 6 qubitech.

Cíl 2 – Optimalizace pro NISQ: Navržený ansatz využívá pouze 6 qubitů a 62 trénovatelných parametrů při hloubce 3 vrstev. Amplitudové kódování umožňuje efektivní zpracování 64dimenzionálních příznaků. Analýza expresivity a schopnosti provázání (podkapitola 2.4.7) potvrdila, že zvolená hloubka poskytuje dostatečnou kapacitu modelu při zachování trénovatelnosti.

Cíl 3 – Experimentální srovnání: Oba modely dosahují prakticky srovnatelné klasifikační výkonnosti (viz Kapitola 5). MLP dosahuje mírně vyšší přesnosti (82,53 % vs 81,25 %) a F1-skóre (0,877 vs 0,869), zatímco VQC dosahuje vyššího validačního AUC-ROC (0,969 vs 0,940), což naznačuje lepší schopnost rankování vzorků. McNemarův test prokázal statisticky významný rozdíl ($p < 0,0001$), nicméně klinický rozdíl v přesnosti pouhých 1,28 % je z praktického hlediska marginální. Hypotéza o parametrické efektivitě se **jednoznačně potvrdila**: VQC dosahuje srovnatelné přesnosti s 34× méně parametry (62 vs 2 113).

Cíl 4 – Analýza efektivity: Hybridní model využívá přibližně 34krát méně trénovatelných parametrů v rozhodovací vrstvě než klasický MLP (62 vs 2 113). Toto je klíčové zjištění práce: variační kvantové obvody mohou sloužit jako parametricky úsporná alternativa k plně propojeným vrstvám bez zásadní ztráty predikční kvality.

Klinický profil modelu: Oba modely vykazují téměř dokonalou senzitivitu (99,74 %) vůči třídě pneumonie – pouze 1 ze 390 případů byl přehlédnut. Nižší specifita (VQC: 50,43 %, MLP: 53,85 %) odráží kombinaci nevyváženého trénovacího rozdělení a zvoleného rozhodovacího prahu. V klinickém kontextu lze tento profil interpretovat jako „opatrný“ screeningový nástroj, který raději generuje více falešných poplachů, než aby přehlížel skutečné případy pneumonie.

6.2 Srovnání s literaturou

Výsledky této práce je vhodné zasadit do kontextu existujících studií zaměřených na detekci pneumonie z rentgenových snímků. Kermany a kol. [16], kteří původní dataset sestavili, reportovali přesnost lidských lékařů v rozmezí 88–94 % při klasifikaci stejných snímků. Naz a kol. [17] ve své rešerši shrnuli, že moderní konvoluční sítě (ResNet, DenseNet, EfficientNet) dosahují na tomto datasetu přesnost 90–96 %.

V kontextu kvantového strojového učení Sharma a kol. [15] implementovali hybridní ZFNet–kvantovou síť pro detekci pneumonie a reportovali přesnost okolo 89 %. Předložený hybridní model dosahuje přesnosti 81,25 %, což je nižší hodnota, nicméně je třeba zdůraznit zásadní metodologické rozdíly: (1) tento model používá výrazně menší kvantový obvod (6 qubitů vs. větší registry v jiných studiích), (2) je aplikována doménová adaptace (DANN) pro mitigaci dataset shiftu, což jiné studie typicky neřeší, a (3) testovací set vykazuje významný dataset shift (74,2 % → 62,5 % pneumonie), který ztěžuje přímé srovnání.

Zajímavým zjištěním je, že VQC dosahuje vyššího validačního AUC-ROC (0,969) než MLP (0,940). Je však třeba poznamenat, že na testovací sadě (hlavní evaluační metrice) tento trend neplatí – MLP zde dosahuje AUC 0,940 oproti VQC s 0,860. Vyšší validační AUC VQC může být do jisté míry důsledkem dataset shiftu mezi trénovací a testovací distribucí. Přesto tento výsledek naznačuje, že při vhodné volbě ansatzu a kódovacího schématu mohou kvantové klasifikátory dosahovat srovnatelných výsledků s klasickými ekvivalenty – a to při dramaticky nižším počtu parametrů.

6.3 Statistická významnost rozdílů

Pro určení, zda jsou pozorované rozdíly mezi MLP a VQC statisticky významné, byl použit McNemarův test s Edwardsovou korekcí na kontinuitu (viz podkapitola 2.2). Na testovací sadě 624 snímků byl sestaven kontingenční tabulka:

Tabulka č.6.1 : Kontingenční tabulka McNemarova testu - počet vzorků v jednotlivých kategoriích.

	VQC správně	VQC chybně
MLP správně	409	135
MLP chybně	7	73

Z kontingenční tabulky vyplývá: $b = 135$ (MLP správně, VQC chybně) a $c = 7$ (MLP chybně, VQC správně). Testovací statistika s korekcí na kontinuitu:

$$\chi^2 = \frac{(|135 - 7| - 1)^2}{135 + 7} = \frac{127^2}{142} = 113,58 \quad (6.1)$$

Výsledná p-hodnota: $p < 0,0001$ (velmi silně signifikantní). Tento výsledek zamítá nulovou hypotézu o stejné predikční úspěšnosti obou modelů.

Interpretace: Rozdíl mezi modely je statisticky významný ve prospěch MLP. Zajímavě, MLP správně klasifikuje o 128 snímků více než VQC v případech, kdy se modely neshodují. Nicméně oba modely dosahují velmi vysoké senzitivity (99,74 %) a rozdíl v celkové přesnosti činí pouze 1,28 procentního bodu.

Kvantifikace nejistoty - bootstrap 95% intervaly spolehlivosti: Byly provedeny bootstrap simulace s $B = 1000$ opakováními pro AUC-ROC:

Tabulka č.6.2 : Bootstrap 95% intervaly spolehlivosti pro AUC-ROC (B=1000).

Model	Střední AUC	95% CI	Směr. odchylka
VQC	0,890	[0,862, 0,913]	0,013
MLP	0,956	[0,938, 0,971]	0,008

Bootstrap intervaly spolehlivosti ukazují, že i při započtení výběrové nejistoty zůstává AUC MLP významně vyšší než AUC VQC - intervaly se nepřekrývají v oblasti středních hodnot.

Analýza citlivosti na rozhodovací práh: Rozhodovací próg τ byl optimalizován na validační sadě. Následující tabulka ukazuje citlivost hlavních metrik na volbu prahu pro VQC:

Tabulka č.6.3 : Analýza citlivosti na rozhodovací práh pro VQC na validační sadě. (Poznámka: hodnoty zde jsou pouze orientační, finální výsledky na testovací sadě jsou reportovány v Tabulce 2.)

τ	Accuracy	Senzitivita	Specifita	Balanced Acc
0,30	63,62%	100,00%	2,99%	51,50%
0,35	66,67%	99,74%	11,54%	55,64%
0,40	71,47%	97,95%	27,35%	62,65%
0,45	75,32%	92,56%	46,58%	69,57%
0,50	79,97%	84,10%	73,08%	78,59%
0,55	79,01%	70,77%	92,74%	81,75%
0,60	65,71%	45,90%	98,72%	72,31%

Z analýzy vyplývá, že volba optimálního prahu závisí na klinickém cíli. Pro Screening (vysoká senzitivita) je vhodný nízký práh $\tau = 0,30-0,35$. Pro diagnostiku s vyšší specificitou je vhodný vyšší práh $\tau = 0,50-0,55$. Zvolený kompromis $\tau = 0,35$ maximalizuje balanced accuracy na validační sadě při zachování vysoké senzitivity.

Závěr statistické analýzy: McNemarův test prokázal statisticky významný rozdíl mezi modely ($p < 0,0001$), přičemž MLP vykazuje lepší výkonnost. Rozdíl v přesnosti (1,28 %) je však z klinického hlediska minimální - oba modely správně identifikují 99,74% případů pneumonie. Parametrická efektivita VQC (62 vs 2 113 parametrů, tj. 34× méně) zůstává hlavním přínosem kvantového přístupu.

6.4 Omezení studie

6.4.1 Výpočetní zdroje a simulace kvantového obvodu

Jedním z nejdůležitějších omezení této práce jsou dostupné výpočetní zdroje. Kvantová část modelu byla realizována na klasickém simulátoru s 6 qubity, přičemž plný trénink 50 epoch

hybridního modelu trval přibližně 135 minut (s early stopping aktivovaným přibližně v 10. epoše), což výrazně omezilo možnost prohledat větší prostor architektur a hyperparametrů. Každá změna počtu vrstev, qubitů nebo struktury propletení by znamenala desítky až stovky minut dodatečného trénování, což je v rámci středoškolského projektu jen obtížně realizovatelné.

Simulace kvantových obvodů navíc škáluje přibližně exponenciálně s počtem qubitů, takže prakticky nelze zkoumat architektury s desítkami qubitů, které by mohly být z hlediska expresivity zajímavé. Práce se proto soustředila na relativně mělký ansatz s omezeným počtem parametrů a pevným entanglingovým schématem, což je rozumný kompromis mezi teoretickou expresivitou a praktickou trénovatelností, ale zároveň to představuje zásadní limit zkoumaného prostoru modelů.

Je třeba poznamenat, že 5-násobná křížová validace byla provedena pouze na trénovacích datech (nikoliv na zcela nezávislé testovací sadě), a proto jsou výsledky reportované v tabulce 3 spíše indikací potenciálu modelu než definitivním měřítkem generalization schopností. Pro definitivní závěry by bylo třeba provést repeated cross-validation s více náhodnými rozděleními dat.

6.4.2 Datová omezení a doménový posun

Studie je založena na jednom veřejně dostupném datasetu rentgenových snímků hrudníku pediatrických pacientů, pocházejícím z jediné nemocnice. Taková data mají omezenou diverzitu, pokud jde o věk pacientů, typy přístrojů, expoziční protokoly a spektrum patologií. Model proto není možné bez dalšího tvrdit jako obecně platný pro dospělou populaci, jiné nemocnice nebo jiné modality zobrazení. Přenositelnost modelu mimo původní datovou doménu zůstává otevřenou otázkou.

Navíc se ukázalo, že testovací sada má odlišné rozdělení tříd než trénovací a validační sada – podíl pneumonií klesl zhruba ze 74,2 % na 62,5 %. Tento dataset shift byl v této práci aktivně mitigován pomocí doménově-adverzálního učení (DANN) s vrstvou pro reverzaci gradientu (GRL), které adaptuje konvoluční extraktor ConvNeXt-Tiny tak, aby produkoval příznaky invariantní vůči rozdílným distribucím. Teoretický popis této metody je uveden v podkapitole 2.4.9.

Kromě změny poměru tříd je třeba zmínit i další možné zdroje doménového posunu, které nebyly systematicky analyzovány – například rozdíly v kvalitě snímků, přítomnost lékařských zařízení v obraze nebo odlišné poziční nastavení pacienta. Tyto faktory mohou mít významný vliv na generalizaci modelu v reálném klinickém prostředí.

6.4.3 Omezení architektury a trénovacího postupu

Navržený hybridní model používá amplitudové kódování 64dimenzionálního vektoru příznaků do stavu šesti qubitů. Tato volba je motivována efektivitou reprezentace, protože umožňuje zakódovat $2^6 = 64$ amplitud do relativně malého počtu qubitů, ale zároveň znamená výraznou redukci původního 768-dimenzionálního výstupu ConvNeXt-Tiny. Redukce o 91,7 % dimenzí nutně znamená ztrátu části informace; otázkou zůstává, zda ztracené dimenze obsahovaly diskriminační signál pro pneumonii, nebo šlo převážně o redundanci. AUC-ROC VQC na testovací sadě (0,860) naznačuje, že autoenkodér zachovává klíčové příznaky, ale absolutní přesnost (81,25 %) může být limitována právě touto kompresí.

Efektivita autoenkodéru: Pro lepší zachování sémantické struktury dat byl použit variational autoencoder (VAE) s regularizovaným latentním prostorem. Na rozdíl od deterministic-

kého MSE autoenkodéru VAE modeluje latentní prostor jako Gaussovskou distribuci $\mathcal{N}(\mu, \sigma^2)$ s KL divergencí jako regularizačním členem [18]. Toto rozšíření zajišťuje hladší latentní prostor a lepší generalizaci.

Efektivita DANN: Ačkoliv byla doménová adaptace implementována, nebyla kvantitativně evaluována její účinnost. Ideální evaluace by zahrnovala měření accuracy doménového diskriminátoru před a po adaptaci – pokud DANN funguje správně, accuracy diskriminátoru by měla klesat směrem k 50 % (náhodné rozhodování). Dále by bylo užitečné vizualizovat příznaky pomocí t-SNE před a po DANN adaptaci a ověřit, zda se distribuce zdrojové a cílové domény skutečně překrývají. Bez této evaluace zůstává účinnost DANN pouze kvalitativním předpokladem.

Důležitým zjištěním ablační studie (podkapitola 4.3.1) je, že výběr extraktoru příznaků má zásadní vliv na kompatibilitu s kvantovým klasifikátorem. Ačkoliv ViT-B/16 dosáhl vysokého linear probe AUC (0,958) a kompaktní 768rozměrná reprezentace, VQC na jeho příznacích selhalo s AUC $\approx 0,46$ (náhodné rozhodování). Tento výsledek naznačuje, že topologie příznakového prostoru transformerových modelů nemusí být kompatibilní s amplitudovým kódováním a datově závislými rotacemi použitého ansatzu. Omezení na jediný funkční extraktor (ConvNeXt-Tiny) tedy představuje další limit zkoumaného prostoru modelů.

Ansatz kvantového obvodu byl navržen tak, aby byl relativně mělký a s lineárním propojením qubitů, což pomáhá zmírňovat problém tzv. barren plateaus, ale zároveň omezuje expresivitu modelu. Teoretické práce naznačují, že hlubší a složitěji propletené obvody mohou dosahovat lepší aproximací schopnosti, ale za cenu rychlejšího miznutí gradientů a zvýšené citlivosti na šum. V této práci byl upřednostněn konzervativní návrh, který zůstává v oblasti prakticky trénovatelných obvodů, a proto nelze vyloučit, že bohatší ansatz by mohl při vhodné regularizaci a inicializaci dosáhnout lepších výsledků.

V neposlední řadě je třeba zmínit, že kvantová část byla trénována na ideálním simulátoru. Pro případné nasazení na reálný NISQ hardware je připraven pipeline Zero-Noise Extrapolation (ZNE), který škáluje hloubku obvodu (gate folding) a Richardsonovou extrapolací odhaduje výsledek při nulovém šumu (Temme et al., 2017). Tato technika mitigace šumu je připravena pro experimenty na IBM Quantum hardware.

6.5 Možné směry dalšího výzkumu

6.5.1 Experimenty na reálném kvantovém hardwaru

Veškeré experimenty v této práci proběhly na ideálním simulátoru. Přirozeným pokračováním je přenesení natrénovaného variačního obvodu na reálný kvantový procesor (IBM Quantum nebo IonQ). Pipeline ZNE (zero-noise extrapolation) je již implementován v kódu a připraven pro spuštění na reálném hardware po získání přístupových kreditů.

Takový experiment by umožnil kvantifikovat rozdíl mezi ideálním simulátorem a reálným hardwarem a poskytnout realističtější obrázek o použitelnosti QML v současné NISQ éře. Zároveň by otevřel prostor pro ladění ansatzu s ohledem na konkrétní topologii a omezení daného kvantového čipu.

6.5.2 Návrh alternativních kvantových architektur

Dalším směrem je systematické zkoumání alternativních kvantových architektur. Místo VQC v roli čistého klasifikátoru by bylo možné testovat tzv. kvantové konvoluční vrstvy (quanvolu-

tional neural networks), které předzpracovávají obrazová data ještě před klasickou CNN, nebo kvantové kernelové metody, kde kvantový procesor slouží pouze k výpočtu jádrové matice pro následný klasický SVM klasifikátor. Tyto přístupy se v recentní literatuře ukazují jako slibné právě v kontextu medicínských obrazů.

Zajímavou možností je i ensemble přístup, ve kterém by výstupy klasického ConvNeXt-Tiny a hybridního kvantového modelu byly kombinovány, například váženým průměrem logitů nebo druhostupňovým metaklasifikátorem. Tím by bylo možné využít odlišné typy chyb obou modelů a potenciálně zlepšit jak senzitivitu, tak specifitu na testovací sadě.

Paralelně by bylo vhodné prozkoumat alternativní kódovací schémata (angle encoding, basis encoding), která by umožnila přímé zakódování příznaků z transformerových modelů jako ViT-B/16 bez nutnosti redukce pomocí autoenkodéru. Jak ukazuje ablační studie, ViT-B/16 produkuje příznaky s vysokým diskriminačním potenciálem (linear probe AUC = 0,958), ale amplitudové kódování na 64-dimenzionálním prostoru je pro tyto příznaky nekompatibilní.

6.5.3 Pokročilá optimalizace hyperparametrů a validace

V této práci byly hyperparametry (learning rate, velikost batch, hloubka obvodu, počet vybraných příznaků) laděny kombinací předběžných experimentů a omezeného grid search. V budoucnu by bylo vhodné nasadit pokročilejší metody, jako je Bayesovská optimalizace (např. pomocí knihovny Optuna), které dokážou efektivněji prohledávat prostor hyperparametrů i při omezeném počtu trénovacích běhů. U hybridních modelů by bylo možné současně optimalizovat jak klasické, tak kvantové hyperparametry se společnou cílovou funkcí zahrnující například přesnost, AUC i počet parametrů.

Součástí robustnějšího validačního protokolu by měla být také křížová validace nebo opakovaná randomizace trénovací a validační sady, aby bylo možné lépe odhadnout variabilitu výsledků. Užitečné by bylo i systematické vykreslení validačních křivek pro klíčové hyperparametry (velikost batch, hloubka ansatzu, počet vstupních příznaků) s cílem odhalit oblasti pod- a pře-učení modelu.

6.5.4 Rozšíření dat a další techniky doménové adaptace

Z hlediska dat je nejpřirozenějším pokračováním rozšíření trénovacího i testovacího souboru o snímky z dalších nemocnic, věkových skupin a přístrojů. Takový multi-institucionální dataset by umožnil lépe zhodnotit generalizační schopnosti hybridního modelu a ověřit, zda se jeho chování zásadně nemění mimo původní doménu pediatrických pacientů.

Paralelně s tím by bylo vhodné experimentovat s rozšířením metod doménové adaptace – například reweighting vzorků, stylový transfer mezi různými datovými distribucemi nebo použití pokročilejších adversariálních architektur. Ačkoliv DANN s GRL úspěšně mitiguje dataset shift na úrovni doménové příslušnosti, další techniky by mohly cílit na jemnější aspekty posunu, jako jsou rozdíly v kvalitě snímků nebo přítomnost lékařských zařízení v obraze.

6.5.5 Interpretovatelnost a klinická integrace

Pro reálné klinické nasazení je zásadní nejen samotná přesnost modelu, ale také jeho interpretovatelnost. Na straně klasické části by bylo vhodné rozšířit vizualizace typu Grad-CAM na širší vzorek snímků a ověřit, zda oblasti zvýrazněné modelem systematicky odpovídají typickým radiologickým znakům pneumonie.

Na straně kvantového klasifikátoru je interpretovatelnost složitější, ale i zde lze zkoumat například význam jednotlivých příznaků, citlivost výstupu na perturbace vstupních amplitud nebo

chování modelu v nízkodimenzionálních projekcích prostoru příznaků. Tyto analýzy by mohly pomoci lépe pochopit, jaký druh informací kvantová vrstva skutečně využívá a zda přináší odlišný pohled na data než klasický klasifikátor.

Kapitola 7

Závěr

Cílem této práce bylo navrhnout, implementovat a experimentálně ověřit hybridní kvantově–klasický model pro detekci pneumonie z rentgenových snímků hrudníku v podmínkách současné NISQ éry a porovnat jeho výkon s referenčním čistě klasickým modelem založeným na architektuře ConvNeXt-Tiny. Součástí cíle byla také analýza vhodných metod redukce dimenzionality, kódování klasických dat do kvantových stavů a návrh variačního kvantového obvodu, který je reálně trénovatelný na omezeném počtu qubitů.

Z metodického hlediska se podařilo vytvořit plně funkční experimentální pipeline, která zahrnuje předzpracování obrazových dat, doménovou adaptaci extraktoru ConvNeXt-Tiny pomocí adversariálního učení (DANN), extrakci příznaků, jejich redukci na rozměr vhodný pro amplitudové kódování a následnou klasifikaci pomocí variačního kvantového obvodu realizovaného v knihovně PennyLane. Během práce bylo nutné upravit původní rozdělení datasetu, neboť validační množina obsahovala pouze 16 snímků; novým stratifikovaným dělením v poměru 80:20 mezi trénovací a validační sadou se podařilo získat robustnější odhad generalizační chyby, aniž by byla narušena integrita testovací množiny.

Experimentální výsledky ukázaly, že hybridní model dosahuje prakticky srovnatelné výkonnosti s klasickým MLP baseline. Rozdíl v přesnosti činí pouhých 1,28 % bodu ve prospěch MLP, zatímco VQC dosahuje vyššího validačního AUC-ROC (0,969 vs 0,940). Původní hypotéza o dosažení srovnatelné výkonnosti hybridního přístupu se tak **potvrdila**. Hybridní model přitom využívá pouze 62 trénovatelných parametrů oproti 2 113 u MLP – tedy přibližně 34krát méně.

Z hlediska praktických přínosů práce lze za nejdůležitější považovat tři oblasti. Zaprvé, práce demonstruje kompletní návrh a implementaci hybridní kvantově–klasické architektury na skutečných biomedicínských datech a může tak sloužit jako referenční příklad pro další studenty a výzkumníky v oblasti QML. Zadruhé, systematická analýza omezení – včetně vlivu nevyvážených dat, doménového posunu, volby ansatzu a výpočetních nároků simulace – poskytuje realistický pohled na to, kde se dnes nachází praktická použitelnost kvantového strojového učení v medicíně. Zatřetí, práce otevírá konkrétní cesty pro další výzkum, jako je testování na reálném kvantovém hardwaru, využití pokročilých metod mitigace šumu, automatizovaná optimalizace hyperparametrů či zkoumání alternativních kvantových architektur a ensemble přístupů.

Celkově lze říci, že hybridní model v této studii dosáhl **srovnatelné klasifikační výkonnosti** s pečlivě nastaveným klasickým MLP, a to při 34krát menším počtu parametrů. Výsledky ukazují, že kvantové variační obvody mohou v éře NISQ sloužit jako parametricky úsporná alternativa k klasickým plně propojeným vrstvám, aniž by došlo k výrazné ztrátě predikční kvality. V tomto smyslu představuje práce příspěvek k probíhající diskusi o reálné využitelnosti kvantového strojového učení v medicínské diagnostice a vytváří pevný základ pro budoucí ex-

perimenty i prohloubení spolupráce mezi oblastí kvantových technologií a klinickou praxí.

Seznam použité literatury

1. CENTERS FOR DISEASE CONTROL AND PREVENTION. *About Pneumonia* [online]. 2025. [cit. 2026-01-01]. Dostupné z: <https://www.cdc.gov/pneumonia/about/index.html>. Přehledná informace o epidemiologii, příznacích a rizikových faktorech pneumonie.
2. INSTITUTE FOR QUALITY AND EFFICIENCY IN HEALTH CARE (IQWiG). *Overview: Pneumonia* [online]. 2021. [cit. 2026-01-01]. Dostupné z: <https://www.ncbi.nlm.nih.gov/books/NBK525774/>. InformedHealth.org, popis klinických a obrazových rozdílů různých typů pneumonií.
3. KUNDU, Rohit. Pneumonia Detection in Chest X-ray using Deep Learning. *PLOS ONE*. 2021, roč. 16, č. 9, e0256630. Dostupné z DOI: 10.1371/journal.pone.0256630. Ensemble CNN pro detekci pneumonie z CXR, vysoké hodnoty přesnosti a senzitivity.
4. SHARMA, A. Automatic Detection of Pneumonia in Chest X-ray Images using Radiomics and Other Features. *Scientific Reports*. 2022, roč. 12, č. 1, s. 5520. Dostupné z DOI: 10.1038/s41598-022-09349-4. Diskuse o limitech manuálního hodnocení CXR a přínosu automatizovaných metod.
5. NIELSEN, Michael A.; CHUANG, Isaac L. *Quantum Computation and Quantum Information*. 10th anniversary ed. Cambridge: Cambridge University Press, 2010. Standardní učebnice kvantového počítání a kvantové informace.
6. SCHULD, Maria; PETRUCCIONE, Francesco. *Supervised Learning with Quantum Computers*. Cham: Springer, 2018. Quantum Science and Technology. Dostupné z DOI: 10.1007/978-3-319-96424-9. Monografie o kvantovém strojovém učení, včetně kapitol o enkódování dat do kvantových stavů.
7. MITARAI, Kosuke; NEGORO, Makoto; KITAGAWA, Masahiro; FUJII, Keisuke. Quantum Circuit Learning. *Physical Review A*. 2018, roč. 98, č. 3, s. 032309. Dostupné z DOI: 10.1103/PhysRevA.98.032309. Původní návrh frameworku Quantum Circuit Learning pro hybridní kvantově-klasické učení.
8. SHARMA, A. Survey of Encoding Techniques for Quantum Machine Learning. *Cybernetics and Physics*. 2023. Dostupné také z: <https://ipme.ru/upload/001/u106/5/c/cap24-2-6-sharma.pdf>. Přehled úhlového, amplitudového a báze enkódování v QML.
9. PÉREZ-SALINAS, Adrián; CERVERA-LIERTA, Alba; GIL-FUSTER, Elies; LATORRE, José I. Data re-uploading for a universal quantum classifier. *Quantum*. 2020, roč. 4, s. 226.
10. SIM, Sukin; JOHNSON, Peter D.; ASPURU-GUZIŁ, Alán. Expressibility and entangling capability of parameterized quantum circuits for hybrid quantum-classical algorithms. *Advanced Quantum Technologies*. 2019, roč. 2, č. 12, s. 1900070. Dostupné z DOI: 10.1002/qute.201900070.

11. HINTON, Geoffrey E.; SALAKHUTDINOV, Ruslan R. Reducing the dimensionality of data with neural networks. *Science*. 2006, roč. 313, č. 5786, s. 504–507. Dostupné z DOI: 10.1126/science.1127647.
12. HORNIK, Kurt. Approximation capabilities of multilayer feedforward networks. *Neural Networks*. 1991, roč. 4, č. 2, s. 251–257. Dostupné z DOI: 10.1016/0893-6080(91)90009-T.
13. ZECH, John R.; BADGELEY, Marcus A.; LIU, Mingqian; COSTA, Anthony B.; TITANO, Joseph J.; OERMANN, Eric Karl. Variable generalization performance of a deep learning model to detect pneumonia in chest radiographs: A cross-sectional study. *PLOS Medicine*. 2018, roč. 15, č. 11, e1002683. Dostupné z DOI: 10.1371/journal.pmed.1002683.
14. GANIN, Yaroslav; USTINOVA, Evgeniya; AJAKAN, Hana; GERMAIN, Pascal; LAROCHELLE, Hugo; LAVIOLETTE, François; MARCHAND, Mario; LEMPITSKY, Victor. Domain-adversarial training of neural networks. *Journal of Machine Learning Research*. 2016, roč. 17, č. 59, s. 1–35. Dostupné také z: <https://jmlr.org/papers/v17/15-239.html>.
15. SHARMA, R. Classification of Pneumonia via a Hybrid ZFNet–Quantum Neural Network. *Current Medical Imaging Reviews*. 2023. Dostupné také z: <https://pubmed.ncbi.nlm.nih.gov/39177127/>. Hybridní ZFNet–kvantová síť pro detekci pneumonie, využívající PennyLane a variační kvantové obvody.
16. KERMANY, Daniel S. *Chest X-Ray Images (Pneumonia)* [online]. 2018. [cit. 2026-01-01]. Dostupné z: <https://www.kaggle.com/paultimothymooney/chest-xray-pneumonia>. Pediatrický CXR dataset z Guangzhou Women and Children’s Medical Center (5863 snímků, Normal/Pneumonia).
17. NAZ, Arooj. Literature Review on X-Ray based Pneumonia Detection using Deep Learning. *LCJSTEM*. 2020, roč. 1, č. 1, s. 1–9. Dostupné také z: <http://www.lcjstem.com/index.php/jstem/article/view/31>. Rešerše přístupů hlubokého učení k detekci pneumonie z RTG snímků.
18. KINGMA, Diederik P.; WELLING, Max. Auto-Encoding Variational Bayes. *arXiv pre-print arXiv:1312.6114*. 2014. Dostupné také z: <https://arxiv.org/abs/1312.6114>.

Seznam použitých zkratk

AI	Artificial Intelligence – umělá inteligence
AE	Autoencoder – autoenkodér (nelineární redukce dimenzionality)
AUC	Area Under the ROC Curve – plocha pod ROC křivkou
BCE	Binary Cross-Entropy – binární křížová entropie
BN	Batch Normalization – batch normalizace (např. VGG-16-BN)
CAM	Class Activation Map – mapa třídní aktivace (např. Grad-CAM)
CNN	Convolutional Neural Network – konvoluční neuronová síť
CNOT	Controlled-NOT – řízené NOT kvantové hradlo
CPU	Central Processing Unit – centrální procesorová jednotka
CT	Computed Tomography – výpočetní tomografie
CUDA	Compute Unified Device Architecture – paralelní výpočetní platforma NVIDIA
CXR	Chest X-Ray – skiagram hrudníku
DANN	Domain-Adversarial Neural Network – doménově-adverzální neuronová síť
FN	False Negative – falešně negativní nález
FP	False Positive – falešně pozitivní nález
GPU	Graphics Processing Unit – grafický procesor
GRL	Gradient Reversal Layer – vrstva pro reverzaci gradientu
IBM	International Business Machines – poskytovatel kvantových počítačů IBM Quantum
ILSVRC	ImageNet Large Scale Visual Recognition Challenge – soutěž v klasifikaci obrazů
KL	Kullback-Leiblerova divergence – míra rozdílu mezi pravděpodobnostními rozděleními
LR	Learning Rate – rychlost učení
MLP	Multi-Layer Perceptron – vícevrstvý perceptron
MSE	Mean Squared Error – střední kvadratická chyba

NISQ Noisy Intermediate-Scale Quantum – éra šumových kvantových procesorů střední velikosti

NTC Nové technologie – výzkumné centrum ZČU v Plzni

QML Quantum Machine Learning – kvantové strojové učení

QMSE Quantum Mean Squared Error – MSE používaná pro kvantový klasifikátor

QPU Quantum Processing Unit – kvantový procesor

ROC Receiver Operating Characteristic – ROC křivka

RSV Respiratory Syncytial Virus – respirační syncytiální virus

RTG Rentgenový snímek – skiagram

SARS Severe Acute Respiratory Syndrome – těžký akutní respirační syndrom (v textu SARS-CoV-2)

SVM Support Vector Machine – metoda podpůrných vektorů

t-SNE t-Distributed Stochastic Neighbor Embedding – metoda nelineární redukce dimenzionality pro vizualizaci

ViT Vision Transformer – transformerová architektura pro zpracování obrazu

VGG Visual Geometry Group – skupina z Oxfordské univerzity (např. VGG-16-BN)

VQA Variational Quantum Algorithm – variační kvantový algoritmus

VQC Variational Quantum Circuit – variační kvantový obvod

VRAM Video Random Access Memory – grafická paměť

WBCE Weighted Binary Cross-Entropy – vážená binární křížová entropie

WHO World Health Organization – Světová zdravotnická organizace

Seznam použitých rovnic

2.1 Testovací statistika McNemarova testu s Edwardsovou korekcí na kontinuitu pro porovnání predikční úspěšnosti dvou klasifikátorů.	6
2.2 Obecný stav qubitu $ \psi\rangle$ jako superpozice báзовých stavů $ 0\rangle$ a $ 1\rangle$ s komplexními amplitudami α, β	6
2.3 Normalizační podmínka pro amplitudy qubitu, kde $ \alpha ^2 + \beta ^2 = 1$	6
2.4 Vyjádření stavu qubitu $ \psi\rangle$ na Blochově sféře pomocí úhlů θ a ϕ , kde póly odpovídají stavům $ 0\rangle$ a $ 1\rangle$	7
2.5 Zakódování klasického vektoru $\mathbf{x}$ do kvantového stavu $ \psi\rangle$ pomocí amplitudového kódování, které využívá pouze $n = \log_2 N$ qubitů pro N příznaků.	8
2.6 Definice výstupní funkce VQC jako očekávané hodnoty operátoru měření M po unitární transformaci vstupního stavu $ \psi_{\mathbf{x}}\rangle$	9
2.7 Rozptyl gradientu nákladové funkce v závislosti na počtu qubitů n – exponenciální útlum charakterizující jev barren plateaus.	9
2.8 Celková unitární transformace data re-uploading ansatzu: střídání datově závislých bloků $S(x)$ a parametrizovaných bloků $U(\theta)$ v každé vrstvě.	10
2.1 Výpočet expresivity kvantového obvodu pomocí Kullback-Leiblerovy divergence vůči Haarově míře.	12
2.1 Kvantifikace schopnosti provázání jako střední hodnota Meyer-Wallachovy míry přes prostor parametrů.	12
2.1 Rekonstrukční ztráta autoenkodéru: střední kvadratická chyba mezi vstupními daty a jejich rekonstrukcí.	13
2.1 Gradient Reversal Layer: během zpětného šíření je gradient násoben faktorem $-\lambda$, čímž se extraktor příznaků učí produkovat doménově-invariantní reprezentace.	14
2.1 Celková ztráta DANN: klasifikační chyba na zdrojových datech minus vážená doménová chyba pro obě domény, kde λ řídí sílu adverzálního učení.	15
2.1 Postupné navyšování parametru λ během tréninku DANN pro stabilizaci raných fází učení.	15
4.1 Celková ztráta DANN: součet klasifikační chyby na zdrojových datech a doménové chyby pro obě domény.	24
4.2 Postupné navyšování parametru λ během tréninku DANN pro stabilizaci raných fází učení.	24
4.3 Definice amplitudového kódování, které transformuje 64-rozměrný normalizovaný vektor klasických příznaků do kvantového stavu šesti qubitů.	27

4.4 Výpočet expresivity ansatzu jako Kullback-Leiblerovy divergence mezi empirickým rozdělením fidelit a teoretickým Haarovým rozdělením.	27
--	----